a00ab772 / prueba_sgd_group

Code Issues 1 Pull requests Actions Projects Security and quality Insights

Settings

main prueba_sgd_group / README.md

a00ab772 Mejorando readme.md 81861e0 · last week

2016 lines (1601 loc) · 108 KB

Preview Code Blame Raw

Índice

- Descripción de la prueba
- Solución aplicada
- Arquitectura de la solución
  - Pre-requisitos
  - Creación del proyecto
  - Instalación de las dependencias
  - Funcionalidad desarrollada
  - Descripción de las pruebas de la funcionalidad desarrollada
  - Ejecución de las pruebas de la funcionalidad desarrollada
  - Diferencias entre el comportamiento entre los almacenamientos overwrite, append y merge
    - test_informe_overwrite_append_merge_CSV_1_registro
    - test_informe_overwrite_append_merge_CSV_REDUCIDOS
  - Obtener un informe del porcentaje de cobertura de código en las pruebas
- Infraestructura as code y workflows CI / CD

Descripción de la prueba

El objetivo de la prueba técnica es que puedas demostrar tus capacidades de desarrollo en el marco de Big Data y Spark, además de los conceptos básicos del ciclo de vida de data engineering.

Somos conscientes de que algunos de los componentes tecnológicos que proponemos para esta prueba técnica quizá no los conozcas, pero pensamos que por tus capacidades podrás adquirir un conocimiento básico en estos días para sacar adelante la prueba.

Los puntos a tratar en la prueba técnica serían los siguientes:

1. Descomprimir el fichero assets.zip recibido junto con este documento.
2. Deberás desarrollar un programa basado en Python (preferentemente) o Scala que haga lo siguiente:

Descripción del programa:

El programa realizado en Python (preferentemente) o Scala debería, dirigido por el fichero de metadatos “metadata.json”, ejecutar un proceso que lea datos desde los orígenes descritos, ejecute las transformaciones indicadas y escriba los datos en los destinos especificados.

Es muy importante que sea un programa que cambie su comportamiento dinámicamente vía los metadatos propuestos y que no sea un desarrollo ad hoc.

Nota: Entiendo que la solución esperada no es un bloque similar a este, sino un código genérico que interpreta y ejecuta cualquier variante del json proporcionado:

```
df_transformado = df
              .filter("sexo != 'Ambos sexos' and municipio != 'N/A'")
              .withColumn("domain", F.lit("demography"))
              .withColumn("load_date", F.current_date())
              .groupBy("provincia", "municipio", "sexo", "load_date")
              .agg(F.sum("total").alias("total_ambos_sexos"))
```

Observación sin quitar un gramo de valor al ejercicio propuesto, quizás la columna `total_ambos_sexos` podría renombrarse a `total_por_sexo` para ajustarse de forma más precisa a la agrupación que estamos haciendo, ya que al incluir el sexo en esta, en realidad estamos sumando el total de cada sexo por separado.

3. Este código tiene que ser compilado y ejecutado usando el csv “data2024.csv” como datos de entrada
4. Después de la primera ejecución, se pide volver a ejecutar usando el csv “data2025.csv”.

Es necesario demostrar el comportamiento solicitado en las salidas (overwrite, append y merge).

5. Adicionalmente, se piden 2 códigos (totalmente aparte del punto 1) para realizar las siguientes comprobaciones (por ejemplo, un test unitario):

   a. Qué filas han cambiado del fichero de 2024 al fichero de 2025

   b. Qué problemas de calidad del dato tiene el fichero de 2025 (Ambos sexos != Hombres + Mujeres)

6. Como ultimo punto, se pide que en un documento de PowerPoint se haga una presentación de cómo se podría implantar un motor como el solicitado (suponiendo funcionalidades extendidas de lectura, transformacion y escritura, no únicamente las solicitadas en esta prueba) en una arquitectura de datos basada en alguna de las clouds más habituales (Azure, Google, AWS, Cloudera).

Ese diseño debe incluir un **Airflow** como orquestador, ademas del resto de servicios necesarios para industrializar una solución de este tipo (bases de datos, storages, etc...).

Incluir también los ciclos de CI/CD correspondientes para realizar el despliegue de todos los componentes de software que fueran necesarios.

En este documento no es necesario explicar ni exponer nada sobre la creación y despliegue de los servicios en cloud mediante IaC (infraestructure as code).

Si tienes que priorizar en qué te enfocas de la prueba técnica porque no tienes suficiente tiempo, el principal objetivo es que nos desmuestres tus capacidades de Python/Scala y Spark.

Así que nos gustaría indicarte que el framework de procesamiento dirigido por metadatos que diseñes e implementes es en lo que más vamos a valorar en términos técnicos y en términos de presentación.

Solución aplicada

Para mi solución he hecho esta selección:

- pyspark
- PyCharm como IDE
- uv
- Cloud AWS y estos componentes:
  - AWS EMR para el cluster de Spark y Hadoop.
    - AWS DynamoDB como base de datos de destino cuando out_type == "table", ya que en DynamoDB un put_item funciona de manera nativa como un upsert, creando el elemento si no existe o sobreescribiéndolo si la clave primaria coincide.

Para ilustrar mejor las diferencias entre append he pensado utilizar claves compuestas; de no hacerlo así o de un modo similar, las filas se sobreescribirían y no veríamos cómo crece el número de líneas cambios tras las distintas ejecuciones. Lo veremos en detalle durante la sesión de test.

- para append en la tabla `demo`, utilizaremos una clave sort key compuesta con los campos municipio, sexo y load_date:

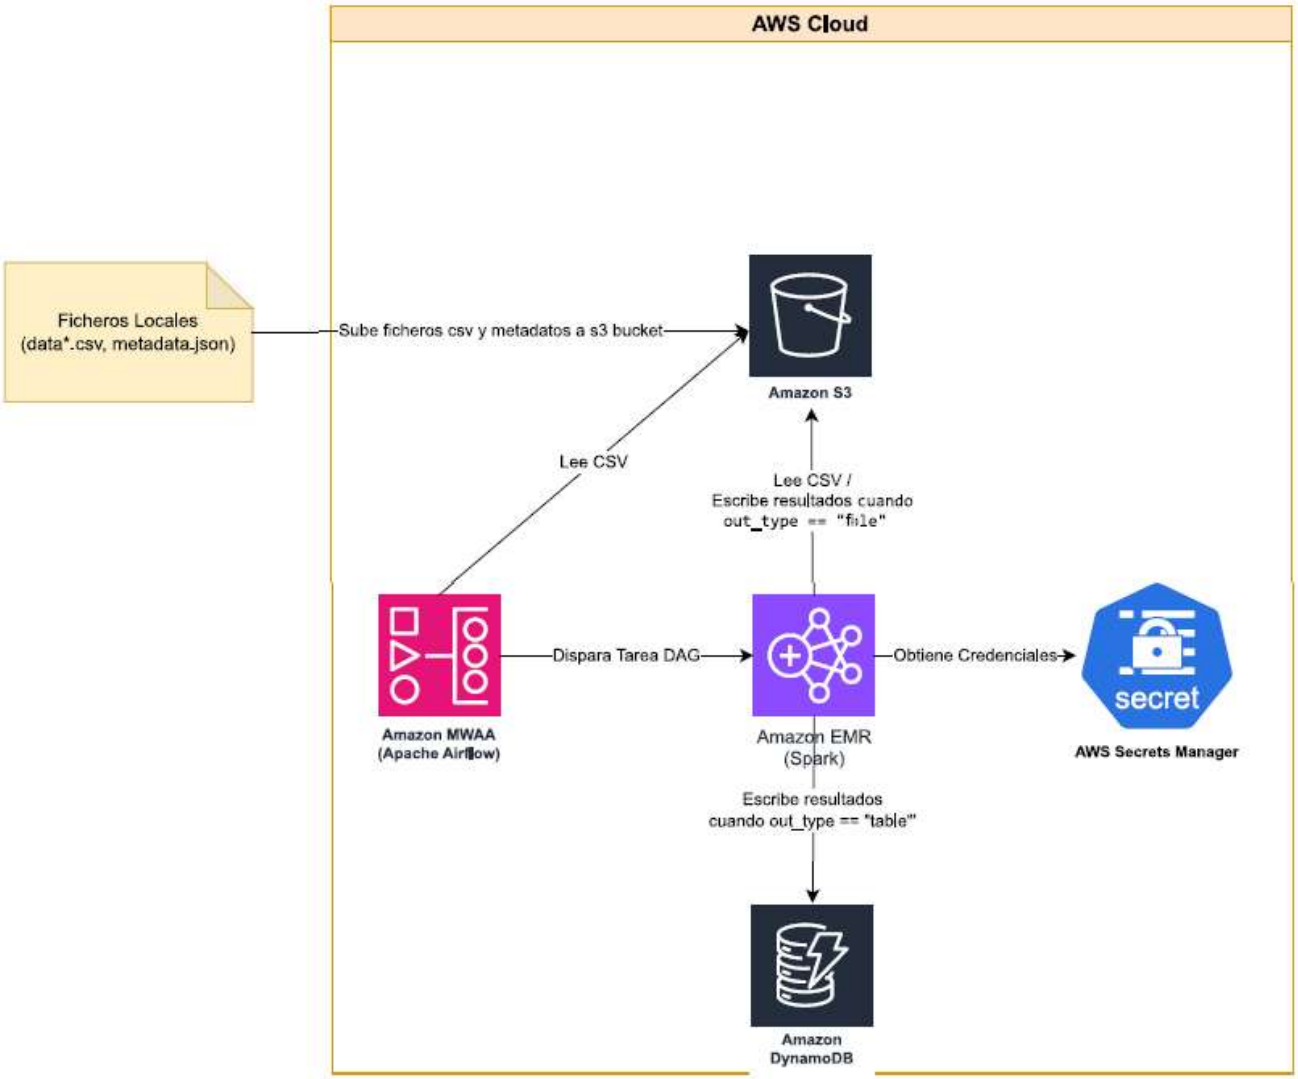
```
dynamodb_client.create_table(
    TableName="demo",
    KeySchema=[
        {"AttributeName": "provincia", "KeyType": "HASH"},
        {"AttributeName": "municipio_sexo_date", "KeyType": "R
    ],
    AttributeDefinitions=[
        {"AttributeName": "provincia", "AttributeType": "S"},
        {"AttributeName": "municipio_sexo_date", "AttributeTyp
    ],
    BillingMode="PAY_PER_REQUEST"
)
```

- para merge en la tabla `raw_demo`, utilizaremos una clave sort key compuesta con los campos municipio y sexo:

```
dynamodb_client.create_table(
    TableName="raw_demo",
    KeySchema=[
        {"AttributeName": "provincia", "KeyType": "HASH"},
        {"AttributeName": "municipio_sexo", "KeyType": "RANGE"
    ],
    AttributeDefinitions=[
        {"AttributeName": "provincia", "AttributeType": "S"},
        {"AttributeName": "municipio_sexo", "AttributeType": "
    ],
    BillingMode="PAY_PER_REQUEST"
)
```

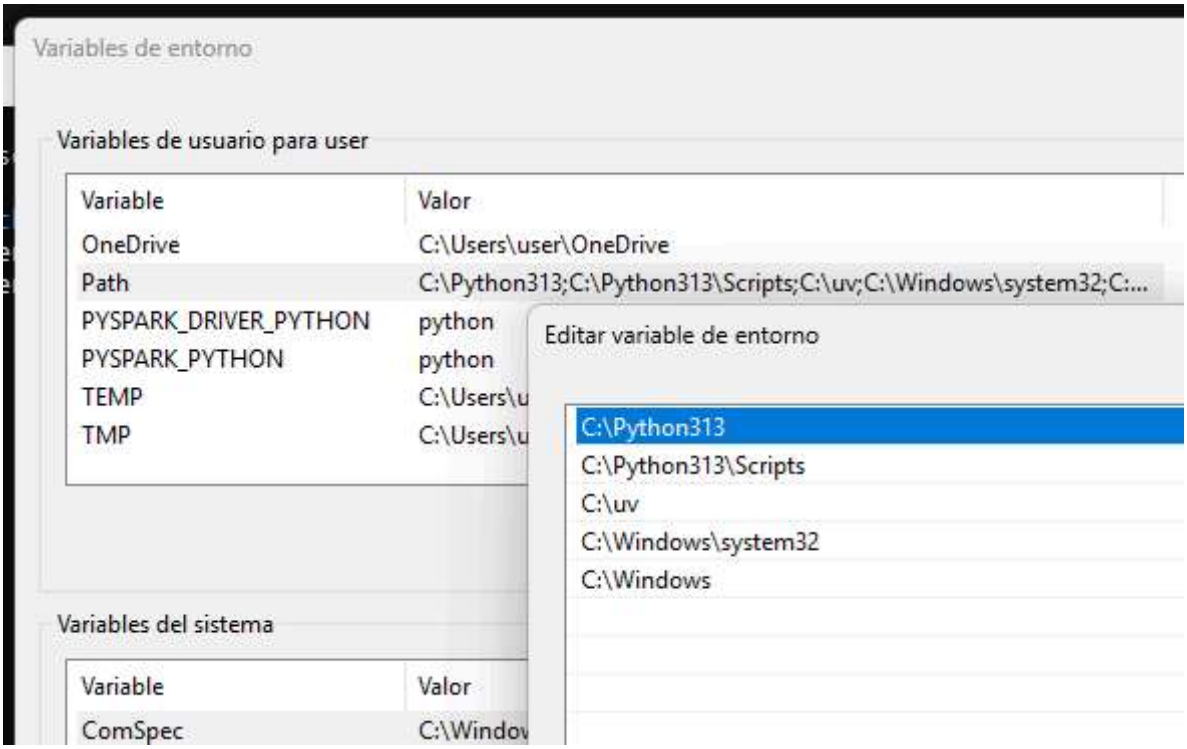
- AWS S3 como sistema de almacenamiento de archivos para guardar los CSV, el archivo metadata.json y los archivos resultantes de la transformación cuando out_type == "file".
- AWS Secrets Manager para almacenar y recuperar las credenciales de acceso al cluster de EMR.
- AWS Managed Workflows para Apache Airflow (MWAA)

Arquitectura de la solución



Pre-requisitos

º Python y opcionalmente, uv




```
user@DESKTOP-SCNMK3I MINGW64 ~/Documents/PycharmProjects/prueba_sgd_group
Thu Aug 27 09:50:55
$ python --version
Python 3.14.6

user@DESKTOP-SCNMK3I MINGW64 ~/Documents/PycharmProjects/prueba_sgd_group
Thu Aug 27 10:33:58
$ uv --version
uv 0.12.0 (b88d7c5c4 2026-07-28 x86_64-pc-windows-msvc)
```

º JDK version 17 o superior. He elegido la 17 porque es la que tengo instalada en mi portátil:

```
C:\Users\user>java --version
openjdk 17.0.20 2026-07-21
OpenJDK Runtime Environment Temurin-17.0.20+8 (build 17.0.20+8)
OpenJDK 64-Bit Server VM Temurin-17.0.20+8 (build 17.0.20+8, mixed mode, sharin
```

Nota

Utilizo JDK Eclipse Temurin porque es la recomendada en en desarrollo para ecosistemas de Big Data y Spark por estos motivos:

► A diferencia de Oracle JDK, es gratuita.

► Su adopción está muy extendida y testada en entornos productivos cloud y on premises.

► Es estable y tiene soporte a largo plazo.

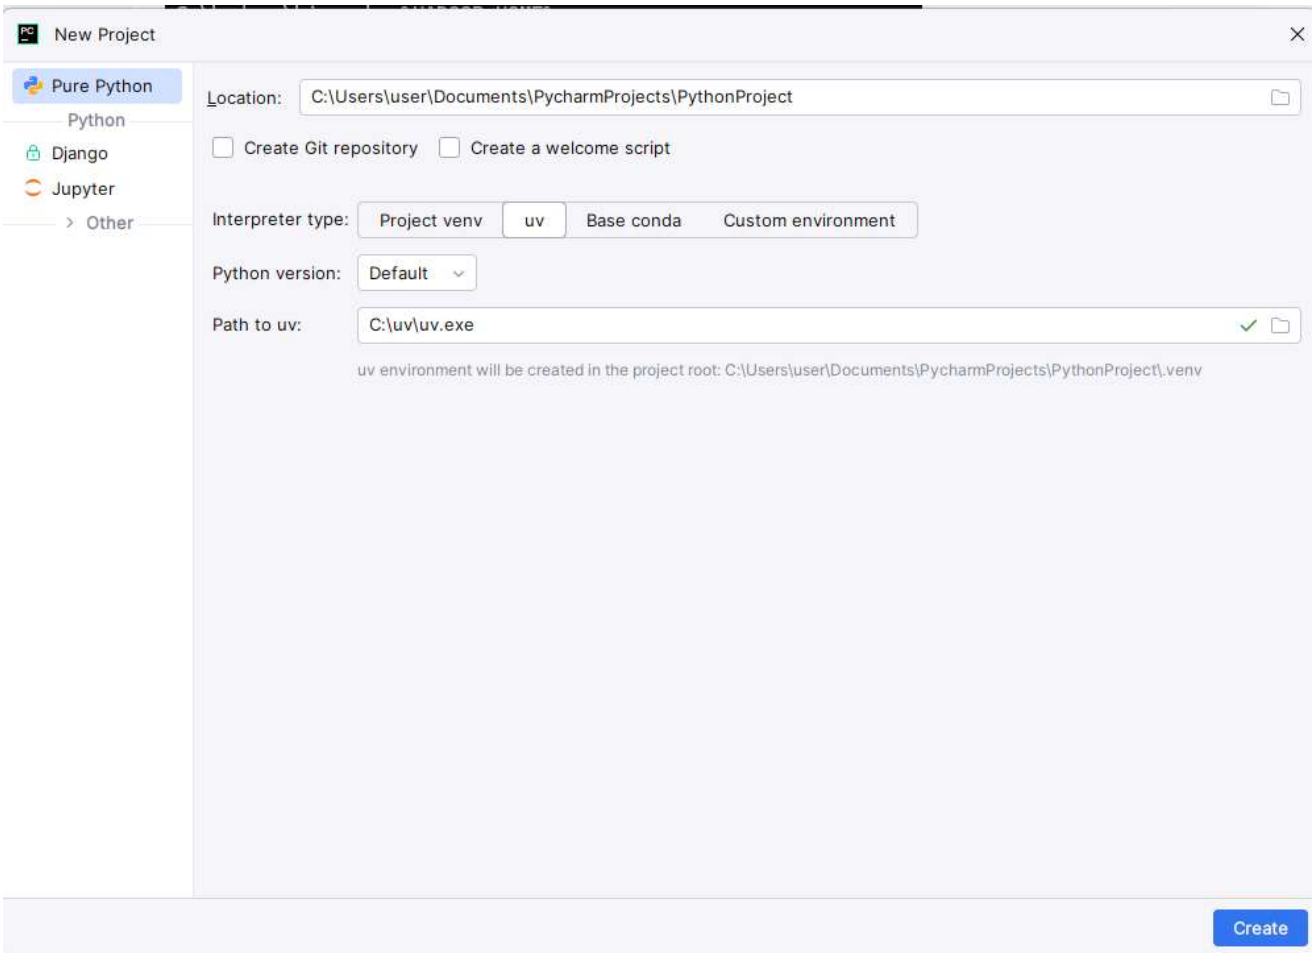
► Es compatible con Apache Spark y está optimizada para integrarse de modo transparente con las dependencias de este lenguaje con la máquina virtual de Java, de modo que experimentaremos muchos menos problemas de compatibilidad que si usamos otro vendedor como Oracle.

º Setup the local HADOOP_HOME configuration:

https://github.com/cdarlint/winutils/tree/master/hadoop-3.3.6/bin



Creación del proyecto



Instalación de las dependencias

Añado una versión de pyspark compatible con la máquina virtual de Java 17 y la versión de python que uso en mi sistema:

```
(prueba_sgd_group) PS C:\Users\user\Documents\PycharmProjects\prueba_sgd_group>
Resolved 3 packages in 2m 56s
      Built pyspark==3.5.9
      Built prueba-sgd-group @ file:///C:/Users/user/Documents/PycharmProjects/
Uninstalled 1 package in 2ms
Installed 3 packages in 323ms
 ~ prueba-sgd-group==0.1.0 (from file:///C:/Users/user/Documents/PycharmProject
 + py4j==0.10.9.9
 + pyspark==3.5.9
```

```
(prueba_sgd_group) PS C:\Users\user\Documents\PycharmProjects\prueba_sgd_group>
Resolved 9 packages in 1.01s
      Built prueba-sgd-group @ file:///C:/Users/user/Documents/PycharmProjects/
Prepared 6 packages in 7.29s
Uninstalled 1 package in 1ms
```

```
Installed 6 packages in 468ms
 + numpy==2.4.6
 + pandas==3.0.5
 ~ prueba-sgd-group==0.1.0 (from file:///C:/Users/user/Documents/PycharmProject
 + python-dateutil==2.9.0.post0
 + six==1.17.0
 + tzdata==2026.3
```

```
(prueba_sgd_group) PS C:\Users\user\Documents\PycharmProjects\prueba_sgd_group>
Resolved 12 packages in 528ms
      Built prueba-sgd-group @ file:///C:/Users/user/Documents/PycharmProjects/
Prepared 4 packages in 85ms
Uninstalled 1 package in 3ms
Installed 4 packages in 34ms
 + delta-spark==3.3.2
 + importlib-metadata==9.0.0
 ~ prueba-sgd-group==0.1.0 (from file:///C:/Users/user/Documents/PycharmProject
 + zipp==4.1.0
```

```
(prueba_sgd_group) PS C:\Users\user\Documents\PycharmProjects\prueba_sgd_group>
Resolved 137 packages in 1.72s
      Built prueba-sgd-group @ file:///C:/Users/user/Documents/PycharmProjects/
Prepared 124 packages in 5.66s
Uninstalled 1 package in 2ms
Installed 124 packages in 833ms
 + a2wsgi==1.10.10
 + aiosmtplib==5.1.2
 + aiosqlite==0.21.0
 + alembic==1.19.1
 + annotated-doc==0.0.5
 + annotated-types==0.8.0
 + anyio==4.14.2
 + apache-airflow==3.3.0
 + apache-airflow-core==3.3.0
 + apache-airflow-providers-common-compat==1.18.0
 + apache-airflow-providers-common-io==1.8.0
 + apache-airflow-providers-common-sql==2.1.0
 + apache-airflow-providers-smtp==3.0.3
 + apache-airflow-providers-standard==1.17.0
 + apache-airflow-task-sdk==1.3.0
 + argcomplete==3.7.2
 + arrow==1.4.0
 + asgiref==3.12.1
 + attrs==26.1.0
 + babel==2.18.0
 + cachetools==7.1.7
 + cadwyn==7.0.0
 + certifi==2026.7.22
```

```
+ cffi==2.1.1
+ charset-normalizer==3.4.9
+ click==8.4.2
+ colorama==0.4.6
+ colorlog==6.12.0
+ cron-descriptor==2.1.0
+ croniter==6.2.4
+ cryptography==50.0.0
+ deprecated==1.3.1
+ dill==0.4.1
+ dnspython==2.8.0
+ email-validator==2.3.0
+ fastapi==0.136.3
+ fastapi-cli==0.0.32
+ fsspec==2026.7.0
+ googleapis-common-protos==1.75.1
+ greenback==1.3.0
+ greenlet==3.5.5
+ grpcio==1.83.0
+ h11==0.16.0
+ httpcore==1.0.9
+ httptools==0.8.0
+ httpx==0.28.1
+ idna==3.18
+ isoduration==20.11.0
+ itsdangerous==2.2.0
+ jinja2==3.1.6
+ jsonschema==4.26.0
+ jsonschema-specifications==2025.9.1
+ lazy-object-proxy==1.12.0
+ libcst==1.9.0
+ linkify-it-py==2.1.0
+ lockfile==0.12.2
+ mako==1.4.1
+ markdown-it-py==4.2.0
+ markupsafe==3.0.3
+ mdurl==0.1.2
+ methodtools==0.4.7
+ more-itertools==11.1.0
+ msgspec==0.21.1
+ natsort==8.4.0
+ opentelemetry-api==1.44.0
+ opentelemetry-exporter-otlp==1.44.0
+ opentelemetry-exporter-otlp-proto-common==1.44.0
+ opentelemetry-exporter-otlp-proto-grpc==1.44.0
+ opentelemetry-exporter-otlp-proto-http==1.44.0
+ opentelemetry-proto==1.44.0
+ opentelemetry-sdk==1.44.0
+ opentelemetry-semantic-conventions==0.65b0
+ outcome==1.3.0.post0
+ packaging==26.3
+ pathlib-abc==0.5.2
+ pathspec==1.1.1
```

```
+ pendulum==3.2.0
+ pluggy==1.6.0
+ protobuf==7.35.1
~ prueba-sgd-group==0.1.0 (from file:///C:/Users/user/Documents/PycharmProjects
+ psutil==7.2.2
+ pycparser==3.0
+ pydantic==2.13.4
+ pydantic-core==2.46.4
+ pydantic-extra-types==2.11.1
+ pydantic-settings==2.15.0
+ pygments==2.20.0
+ pygtrie==2.5.0
+ pyjwt==2.13.0
+ python-daemon==3.1.2
+ python-dotenv==1.2.2
+ python-multipart==0.0.32
+ python-slugify==8.0.4
+ pyyaml==6.0.3
+ referencing==0.37.0
+ requests==2.34.2
+ rich==15.0.0
+ rich-argparse==1.8.0
+ rich-toolkit==0.20.3
+ rpds-py==2026.6.3
+ setproctitle==1.3.7
+ shellingham==1.5.4
+ sniffio==1.3.1
+ sqlalchemy==2.0.52
+ sqlparse==0.5.5
+ starlette==1.6.0
+ structlog==26.1.0
+ svcs==26.1.0
+ tabulate==0.10.0
+ tenacity==9.1.4
+ termcolor==3.3.0
+ text-unidecode==1.3
+ typer==0.27.1
+ typing-extensions==4.16.0
+ typing-inspection==0.4.3
+ uc-micro-py==2.0.0
+ universal-pathlib==0.3.10
+ urllib3==2.7.0
+ uuid6==2025.0.1
+ uvicorn==0.52.1
+ watchfiles==1.2.0
+ websockets==17.0.1
+ wirerope==1.0.0
+ wrapt==2.3.0
```

```
(prueba_sgd_group) PS C:\Users\user\Documents\PycharmProjects\prueba_sgd_group>
Resolved 139 packages in 537ms
      Built prueba-sgd-group @ file:///C:/Users/user/Documents/PycharmProjects/
Prepared 3 packages in 117ms
Uninstalled 1 package in 2ms
Installed 3 packages in 52ms
 + iniconfig==2.3.0
 ~ prueba-sgd-group==0.1.0 (from file:///C:/Users/user/Documents/PycharmProject
 + pytest==9.1.1
(prueba_sgd_group) PS C:\Users\user\Documents\PycharmProjects\prueba_sgd_group>
Resolved 140 packages in 272ms
      Built prueba-sgd-group @ file:///C:/Users/user/Documents/PycharmProjects/
Prepared 2 packages in 83ms
Uninstalled 1 package in 2ms
Installed 2 packages in 21ms
 ~ prueba-sgd-group==0.1.0 (from file:///C:/Users/user/Documents/PycharmProject
 + pytest-mock==3.15.1
(prueba_sgd_group) PS C:\Users\user\Documents\PycharmProjects\prueba_sgd_group>
Resolved 143 packages in 527ms
      Built prueba-sgd-group @ file:///C:/Users/user/Documents/PycharmProjects/
Prepared 3 packages in 254ms
Uninstalled 1 package in 2ms
Installed 3 packages in 55ms
 + coverage==7.15.4
 ~ prueba-sgd-group==0.1.0 (from file:///C:/Users/user/Documents/PycharmProject
 + pytest-cov==7.1.0
(prueba_sgd_group) PS C:\Users\user\Documents\PycharmProjects\prueba_sgd_group>
Resolved 151 packages in 492ms
      Built prueba-sgd-group @ file:///C:/Users/user/Documents/PycharmProjects/
Prepared 9 packages in 2.23s
Uninstalled 1 package in 1ms
Installed 9 packages in 781ms
 + boto3==1.43.69
 + botocore==1.43.69
 + jmespath==1.1.0
 + moto==5.2.2
 ~ prueba-sgd-group==0.1.0 (from file:///C:/Users/user/Documents/PycharmProject
 + responses==0.26.2
 + s3transfer==0.19.2
 + werkzeug==3.1.8
 + xmltodict==1.0.4

(prueba_sgd_group) PS C:\Users\user\Documents\PycharmProjects\prueba_sgd_group>
Resolved 154 packages in 889ms
      Built prueba-sgd-group @ file:///C:/Users/user/Documents/PycharmProjects/
Prepared 4 packages in 118ms
Uninstalled 1 package in 4ms
Installed 4 packages in 35ms
 + boto3-stubs==1.43.69
 + botocore-stubs==1.43.67
 ~ prueba-sgd-group==0.1.0 (from file:///C:/Users/user/Documents/PycharmProject
 + types-s3transfer==0.16.0
```

```
(prueba_sgd_group) PS C:\Users\user\Documents\PycharmProjects\prueba_sgd_group>
Resolved 158 packages in 232ms
Uninstalled 5 packages in 47ms
Installed 5 packages in 315ms
 - apache-airflow==3.3.0
 + apache-airflow==2.11.2
 - marshmallow==4.3.1
 + marshmallow==3.26.2
 - rich==15.0.0
 + rich==13.9.4
 - sqlalchemy==2.0.52
 + sqlalchemy==1.4.54
 - universal-pathlib==0.3.10
 + universal-pathlib==0.2.6
```

En cualquier momento podemos solucionar inconsistencias en las dependencias con este comando:

```
(prueba_sgd_group) PS C:\Users\user\Documents\PycharmProjects\prueba_sgd_group>
Resolved 154 packages in 1ms
      Built prueba-sgd-group @ file:///C:/Users/user/Documents/PycharmProjects/
Uninstalled 150 packages in 3.55s
Installed 150 packages in 4.02s
 ~ a2wsgi==1.10.10
 ~ aiosmtplib==5.1.2
 ~ aiosqlite==0.21.0
 ~ alembic==1.19.1
 ~ annotated-doc==0.0.5
 ~ annotated-types==0.8.0
 ~ anyio==4.14.2
 ~ apache-airflow==3.3.0
 ~ apache-airflow-core==3.3.0
 ~ apache-airflow-providers-common-compat==1.18.0
 ~ apache-airflow-providers-common-io==1.8.0
 ~ apache-airflow-providers-common-sql==2.1.0
 ~ apache-airflow-providers-smtp==3.0.3
 ~ apache-airflow-providers-standard==1.17.0
 ~ apache-airflow-task-sdk==1.3.0
 ~ argcomplete==3.7.2
 ~ arrow==1.4.0
 ~ asgiref==3.12.1
 ~ attrs==26.1.0
 ~ babel==2.18.0
 ~ boto3==1.43.69
 ~ boto3-stubs==1.43.69
 ~ botocore==1.43.69
 ~ botocore-stubs==1.43.67
 ~ cachetools==7.1.7
 ~ cadwyn==7.0.0
```

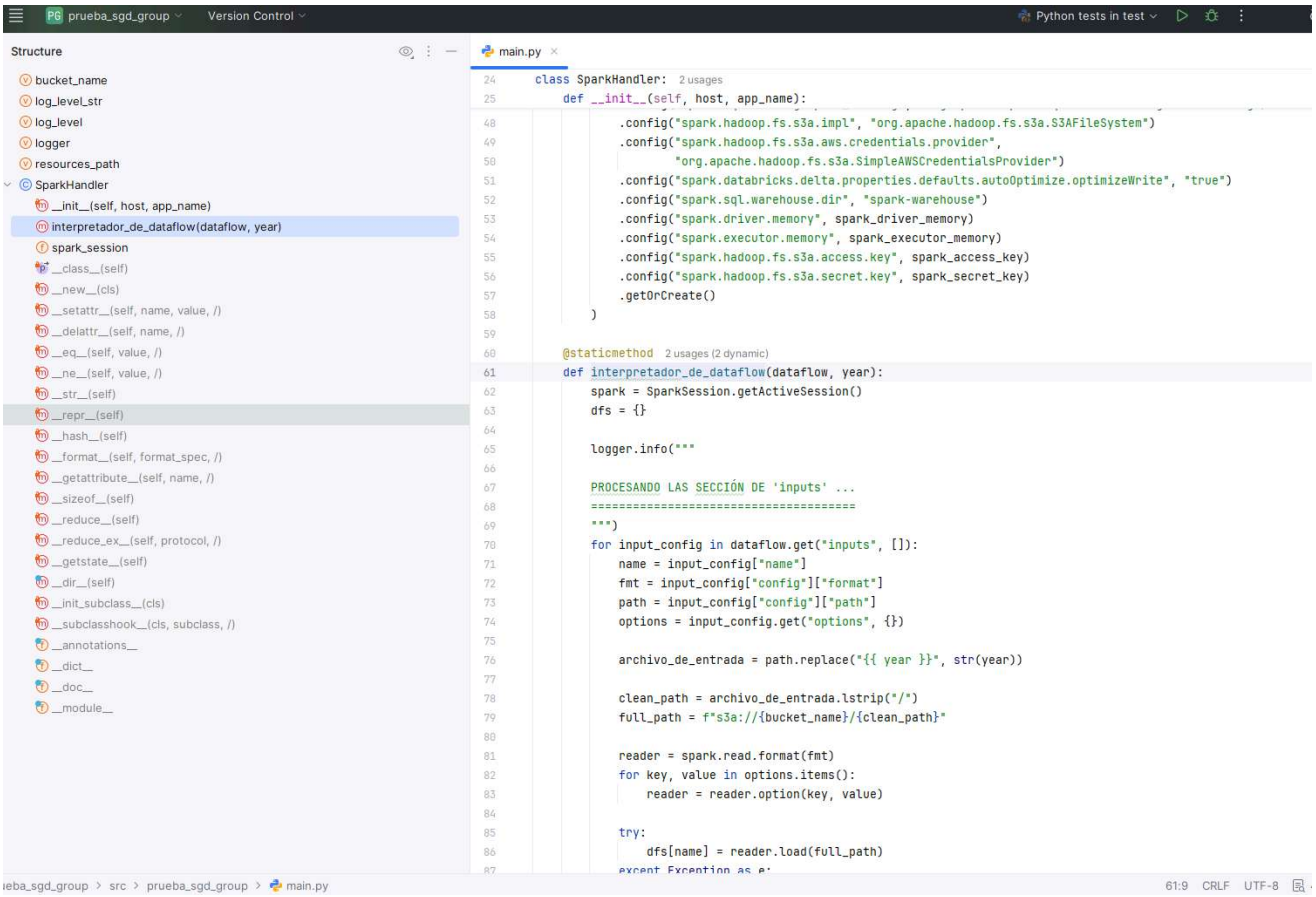
```
        ~ certifi==2026.7.22
        ~ cffi==2.1.1
        ~ charset-normalizer==3.4.9
        ~ click==8.4.2
        ~ colorama==0.4.6
        ~ colorlog==6.12.0
        ~ coverage==7.15.4
        ~ cron-descriptor==2.1.0
        ~ croniter==6.2.4
        ~ cryptography==50.0.0
        ~ delta-spark==3.3.2
        ~ deprecated==1.3.1
        ~ dill==0.4.1
        ~ dnspython==2.8.0
        ~ email-validator==2.3.0
        ~ fastapi==0.136.3
        ~ fastapi-cli==0.0.32
        ~ fsspec==2026.7.0
        ~ googleapis-common-protos==1.75.1
        ~ greenback==1.3.0
        ~ greenlet==3.5.5
        ~ grpcio==1.83.0
        ~ h11==0.16.0
        ~ httpcore==1.0.9
        ~ httptools==0.8.0
        ~ httpx==0.28.1
        ~ idna==3.18
        ~ importlib-metadata==9.0.0
        ~ iniconfig==2.3.0
        ~ isoduration==20.11.0
        ~ itsdangerous==2.2.0
        ~ jinja2==3.1.6
        ~ jmespath==1.1.0
        ~ jsonschema==4.26.0
        ~ jsonschema-specifications==2025.9.1
        ~ lazy-object-proxy==1.12.0
        ~ libcst==1.9.0
        ~ linkify-it-py==2.1.0
        ~ lockfile==0.12.2
        ~ mako==1.4.1
        ~ markdown-it-py==4.2.0
        ~ markupsafe==3.0.3
        ~ mdurl==0.1.2
        ~ methodtools==0.4.7
        ~ more-itertools==11.1.0
        ~ moto==5.2.2
        ~ msgspec==0.21.1
        ~ natsort==8.4.0
        ~ numpy==2.4.6
        ~ opentelemetry-api==1.44.0
        ~ opentelemetry-exporter-otlp==1.44.0
        ~ opentelemetry-exporter-otlp-proto-common==1.44.0
        ~ opentelemetry-exporter-otlp-proto-grpc==1.44.0
```

```
    ~ opentelemetry-exporter-otlp-proto-http==1.44.0
    ~ opentelemetry-proto==1.44.0
    ~ opentelemetry-sdk==1.44.0
    ~ opentelemetry-semantic-conventions==0.65b0
    ~ outcome==1.3.0.post0
    ~ packaging==26.3
    ~ pandas==3.0.5
    ~ pathlib-abc==0.5.2
    ~ pathspec==1.1.1
    ~ pendulum==3.2.0
    ~ pluggy==1.6.0
    ~ protobuf==7.35.1
    ~ prueba-sgd-group==0.1.0 (from file:///C:/Users/user/Documents/PycharmProjects
    ~ psutil==7.2.2
    ~ py4j==0.10.9.9
    ~ pycparser==3.0
    ~ pydantic==2.13.4
    ~ pydantic-core==2.46.4
    ~ pydantic-extra-types==2.11.1
    ~ pydantic-settings==2.15.0
    ~ pygments==2.20.0
    ~ pygtrie==2.5.0
    ~ pyjwt==2.13.0
    ~ pyspark==3.5.9
    ~ pytest==9.1.1
    ~ pytest-cov==7.1.0
    ~ pytest-mock==3.15.1
    ~ python-daemon==3.1.2
    ~ python-dateutil==2.9.0.post0
    ~ python-dotenv==1.2.2
    ~ python-multipart==0.0.32
    ~ python-slugify==8.0.4
    ~ pyyaml==6.0.3
    ~ referencing==0.37.0
    ~ requests==2.34.2
    ~ responses==0.26.2
    ~ rich==15.0.0
    ~ rich-argparse==1.8.0
    ~ rich-toolkit==0.20.3
    ~ rpds-py==2026.6.3
    ~ s3transfer==0.19.2
    ~ setproctitle==1.3.7
    ~ shellingham==1.5.4
    ~ six==1.17.0
    ~ sniffio==1.3.1
    ~ sqlalchemy==2.0.52
    ~ sqlparse==0.5.5
    ~ starlette==1.6.0
    ~ structlog==26.1.0
    ~ svcs==26.1.0
    ~ tabulate==0.10.0
    ~ tenacity==9.1.4
    ~ termcolor==3.3.0
```

~ text-unidecode==1.3
~ typer==0.27.1
~ types-s3transfer==0.16.0
~ typing-extensions==4.16.0
~ typing-inspection==0.4.3
~ tzdata==2026.3
~ uc-micro-py==2.0.0
~ universal-pathlib==0.3.10
~ urllib3==2.7.0
~ uuid6==2025.0.1
~ uvicorn==0.52.1
~ watchfiles==1.2.0
~ websockets==17.0.1
~ werkzeug==3.1.8
~ wirerope==1.0.0
~ wrapt==2.3.0
~ xmltodict==1.0.4
~ zipp==4.1.0

Funcionalidad desarrollada

El método `interpretador_de_dataflow(dataflow, year)` recibe el dataflow del fichero de metadatos “metadata.json” y el año del CSV que vamos a procesar, el primer paso consiste en leer los datos de entrada:



- A continuación ejecuta las transformaciones indicadas en el dataflow:

main.py

```
class SparkHandler:  2 usages
    def interpretador_de_dataflow(dataflow, year):


        logger.info("""

        PROCESANDO LAS SECCIÓN DE 'transformations' ...
        ================================================
        """)
        transformations = dataflow["transformations"]

        for transformation in transformations:

            t_type = transformation["type"]
            t_config = transformation["config"]

            if t_type == "add_fields":
                for field in t_config["fields"]:
                    field_name = field["name"]
                    expr = field["expression"]
                    if expr.startswith("'") and expr.endswith("'"):
                        df_transformado = df_transformado.withColumn(field_name, lit(expr.strip("'")))
                    elif expr == "current_date()":
                        df_transformado = df_transformado.withColumn(field_name, current_date())

            elif t_type == "filter":
                df_transformado = df_transformado.filter(t_config["filter"])

            elif t_type == "group":
                group_fields = t_config["group_fields"]
                aggregations = t_config["aggregations"]

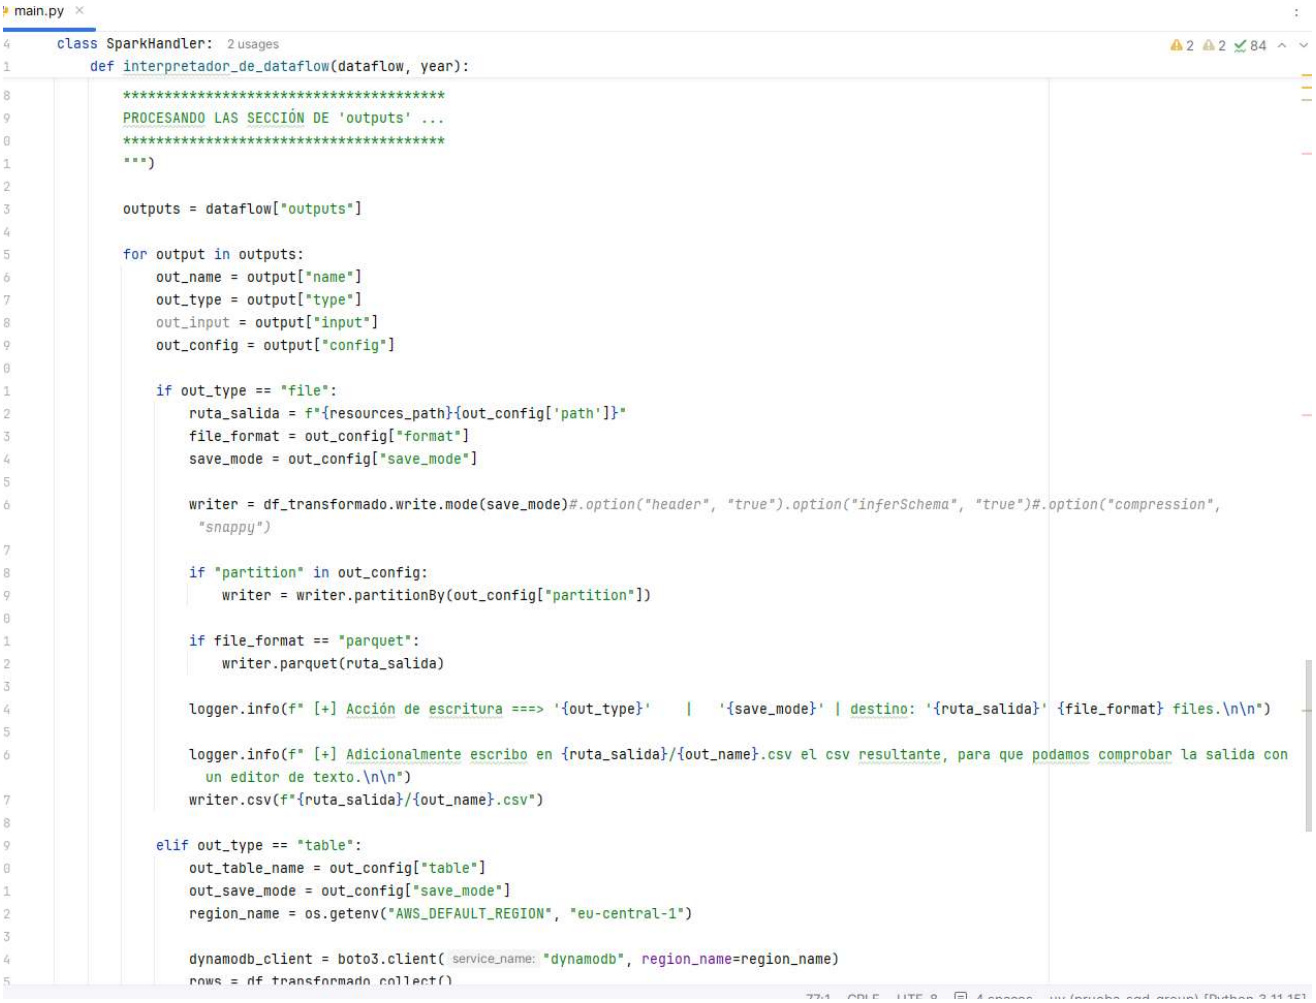
                # Nota: incluyo en el group el campo load_date para evitar que falle la escritura de la sección de 'output' que parti
                 campo
                columnas_de_particionado = [col for col in ["load_date"] if col in df_transformado.columns]
                columnas_de_agregacion = list(set(group_fields + columnas_de_particionado))

                condicion_de_agregacion = [F.expr(agg_str) for agg_str in aggregations]
                df_transformado = df_transformado.groupBy(*columnas_de_agregacion).agg(*condicion_de_agregacion)

            logger.info(f" [+] Aplicamos al dataframe el siguiente elemento de la lista de 'transformations': '{t_type}' ==> {t_confi
            if logger.isEnabledFor(logging.DEBUG):
                df_transformado.show(truncate=False)
```

77:1 CRLF UTF-8 4 spaces uv (prueba_sgd_

- Escribe los resultados en los destinos especificados:



```
main.py
class SparkHandler:  2 usages
    def interpretador_de_dataflow(dataflow, year):
        ****************************************
        PROCESANDO LAS SECCIÓN DE 'outputs' ...
        ****************************************
        """)

        outputs = dataflow["outputs"]

        for output in outputs:
            out_name = output["name"]
            out_type = output["type"]
            out_input = output["input"]
            out_config = output["config"]

            if out_type == "file":
                ruta_salida = f"{resources_path}{out_config['path']}"
                file_format = out_config["format"]
                save_mode = out_config["save_mode"]

                writer = df_transformado.write.mode(save_mode)#.option("header", "true").option("inferSchema", "true")#.option("compression",
                 "snappy")

                if "partition" in out_config:
                    writer = writer.partitionBy(out_config["partition"])

                if file_format == "parquet":
                    writer.parquet(ruta_salida)

                logger.info(f" [+] Acción de escritura ===> '{out_type}'    |   '{save_mode}' | destino: '{ruta_salida}' {file_format} files.\n\n")

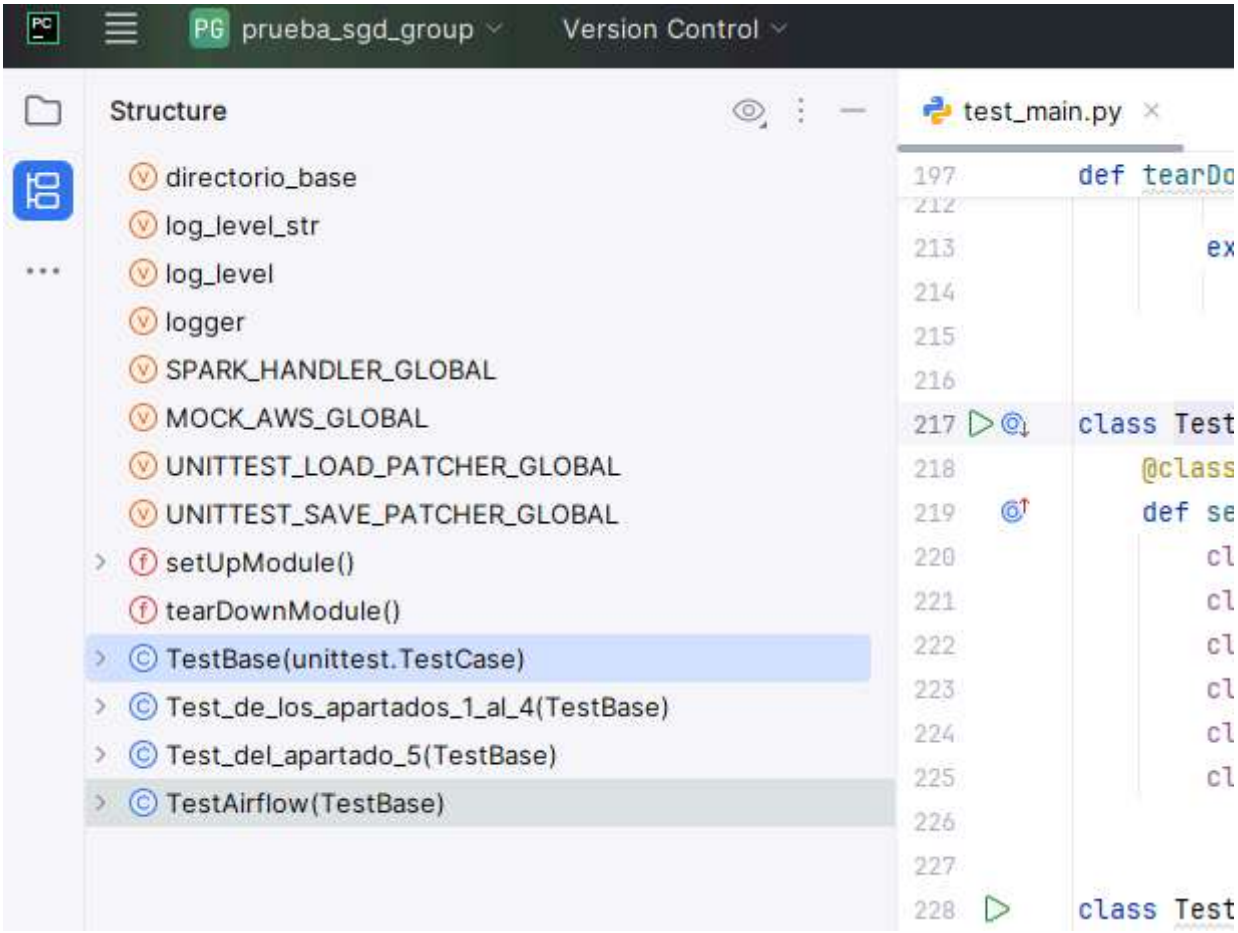
                logger.info(f" [+] Adicionalmente escribo en {ruta_salida}/{out_name}.csv el csv resultante, para que podamos comprobar la salida con
                  un editor de texto.\n\n")
                writer.csv(f"{ruta_salida}/{out_name}.csv")

            elif out_type == "table":
                out_table_name = out_config["table"]
                out_save_mode = out_config["save_mode"]
                region_name = os.getenv("AWS_DEFAULT_REGION", "eu-central-1")

                dynamodb_client = boto3.client( service_name: "dynamodb", region_name=region_name)
                rows = df_transformado.collect()
```

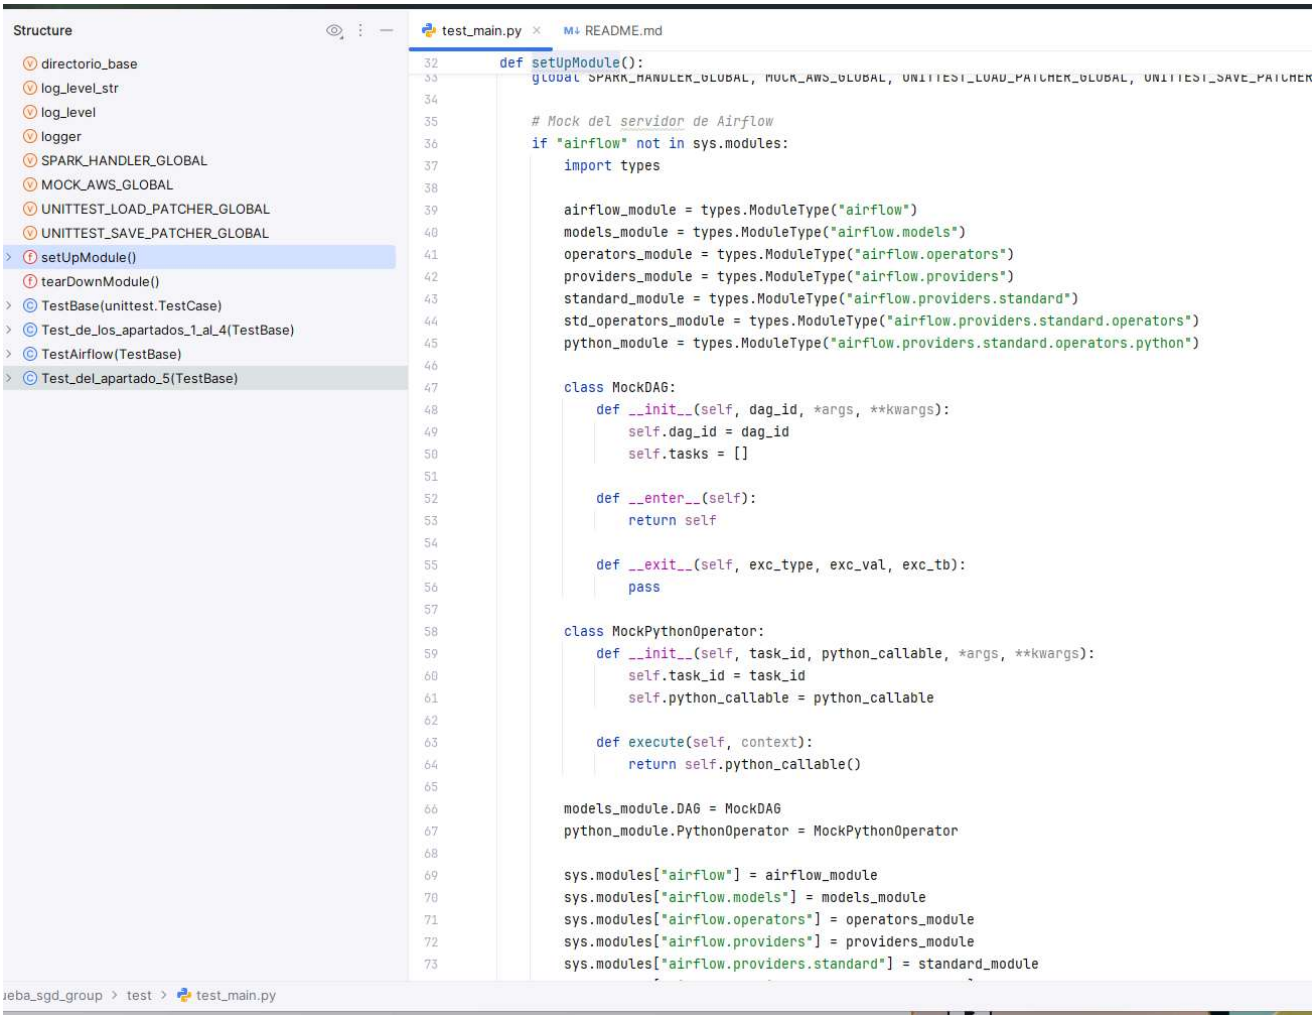
Descripción de las pruebas de la funcionalidad desarrollada

La infraestructura de test está contenida en el archivo test_main.py:

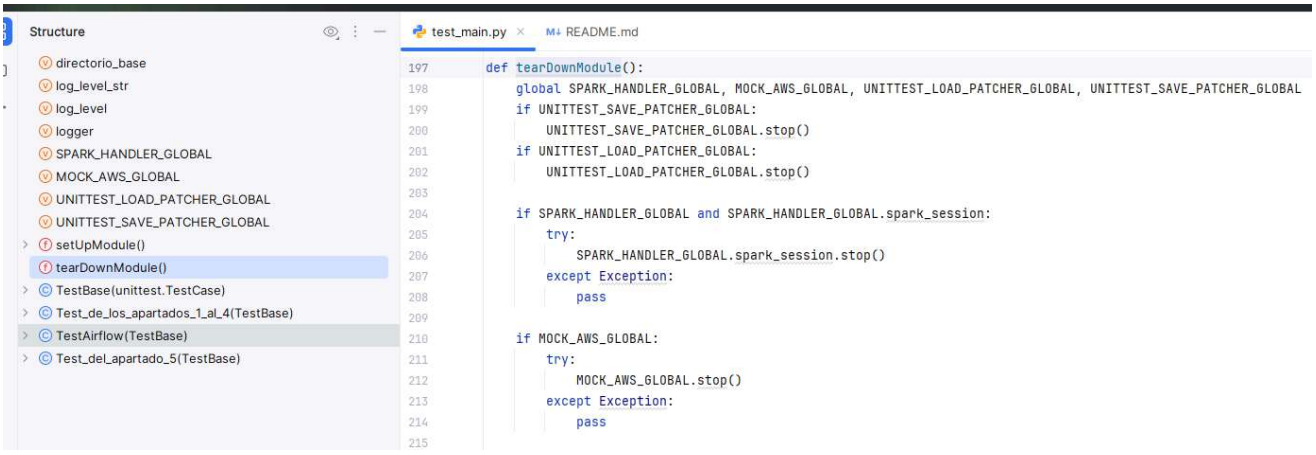


Los componentes principales de este archivo son:

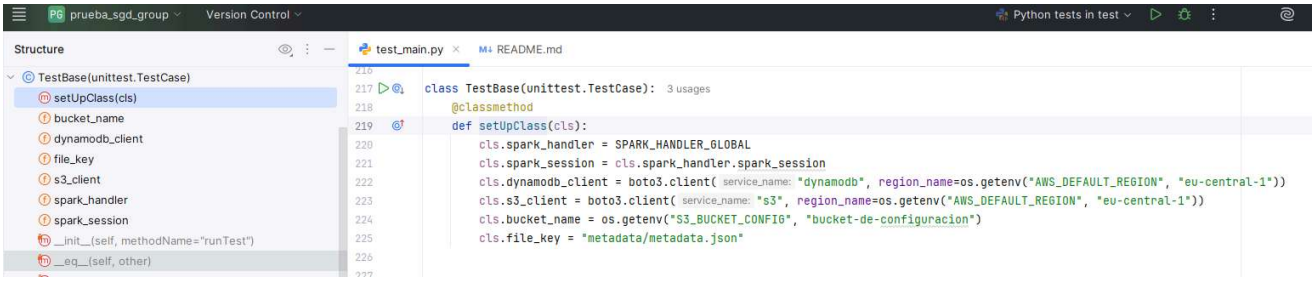
- La función setUpModule() - Mockea los servicios de AWS y el cluster local de Spark



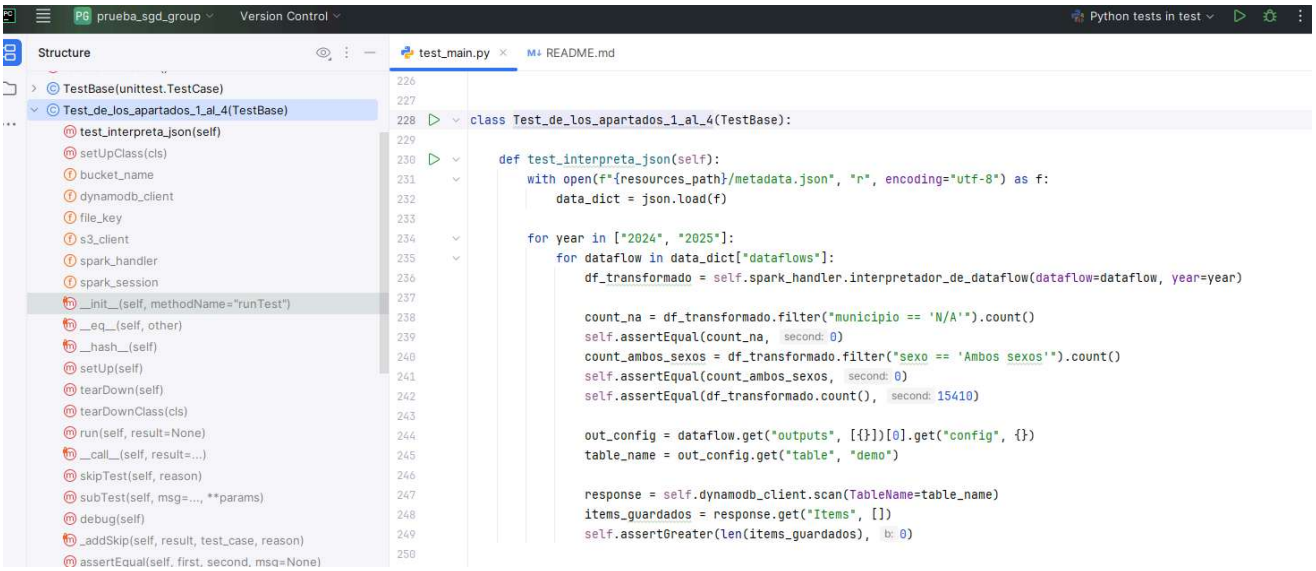
- La función tearDownModule() - Elimina la infraestructura mockeada.



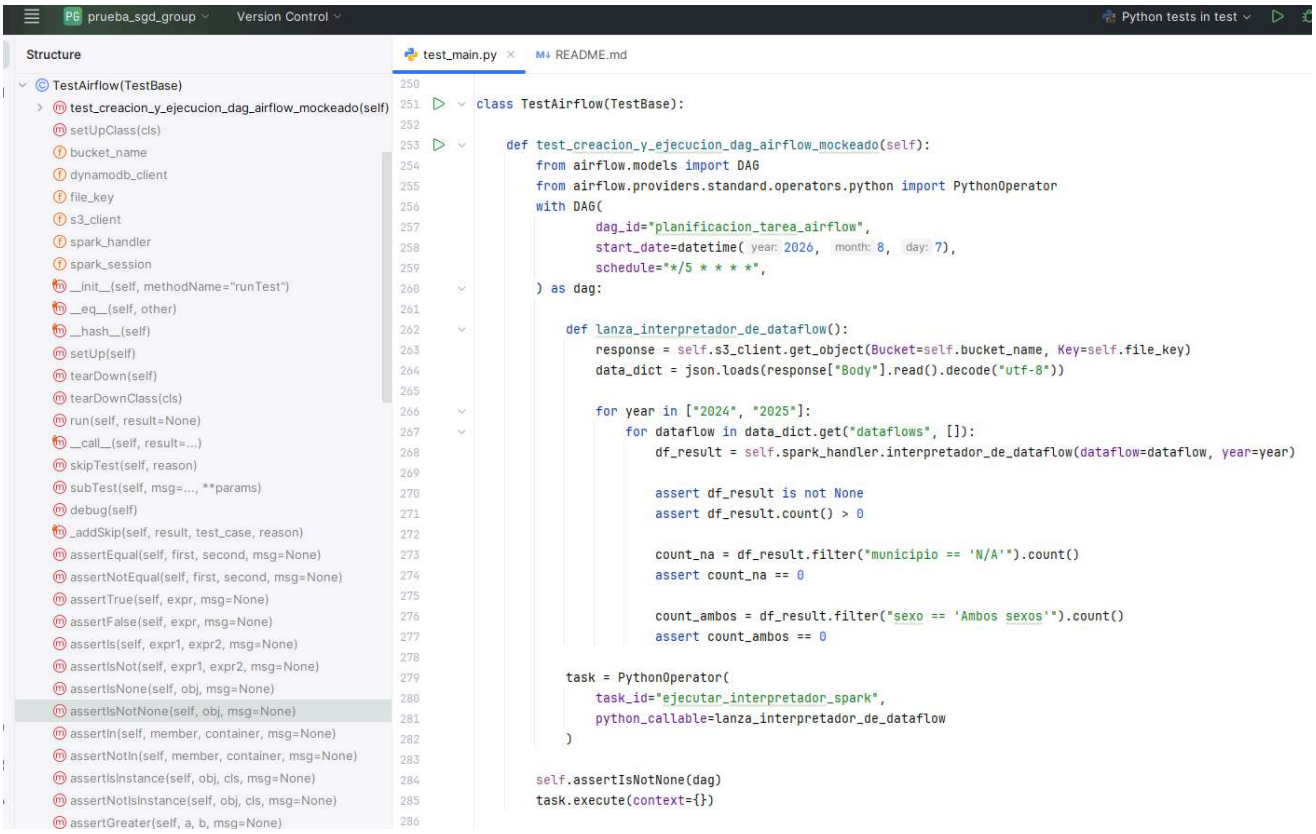
- La clase TestBase - Inicializa los clientes que acceden a los componentes AWS y al cluster local de Spark y Hadoop:



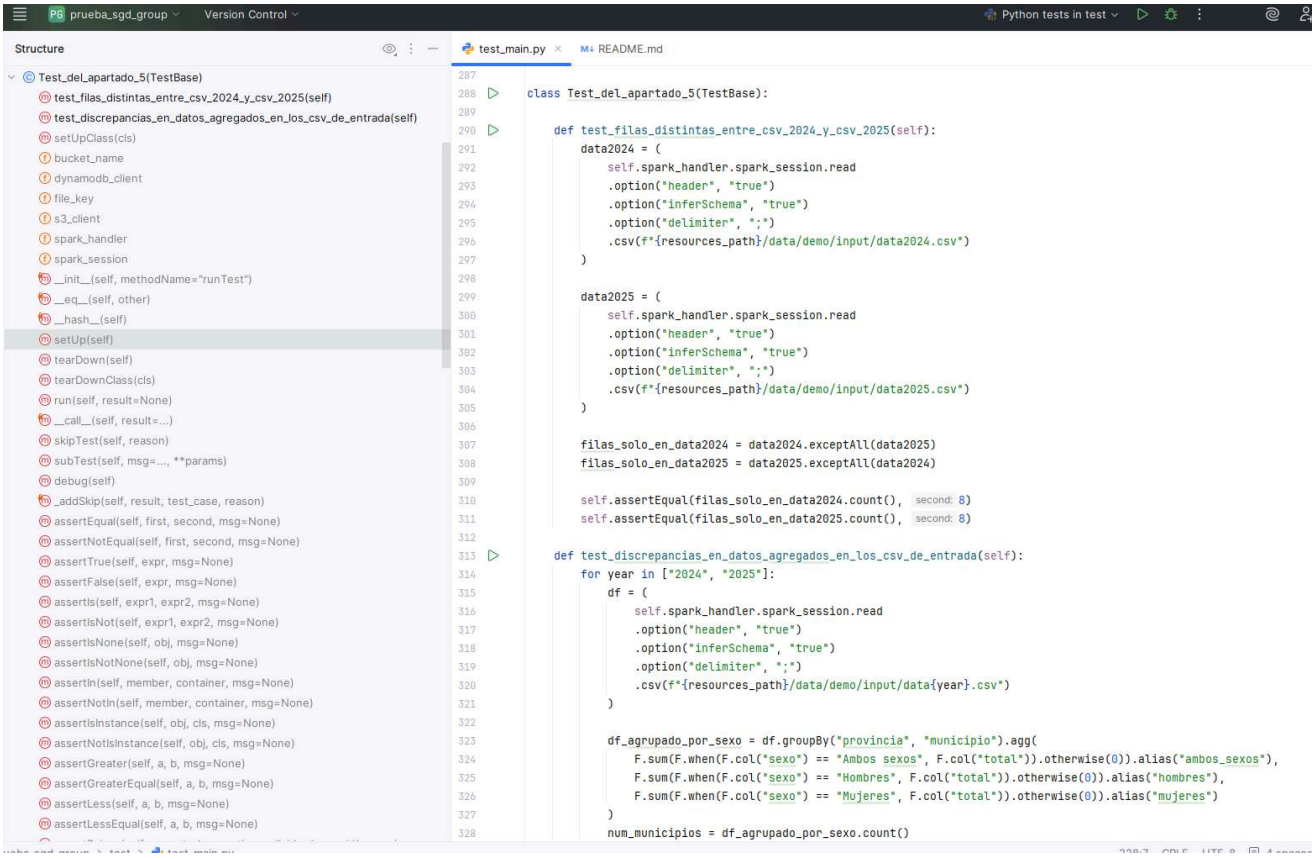
- La clase Test_de_los_apartados_1_al_4(TestBase) - Ejecuta y valida el método `interpretador_de_dataflow(dataflow, year)` con todos los los dataflows contenidos en el archivo `metadata.json` para todos los csv de entrada:



- La clase TestAirflow(TestBase) - Planifica en el servidor mockeado de Airflow una tarea recurrente que ejecuta cada cinco minutos el método `interpretador_de_dataflow(dataflow, year)`

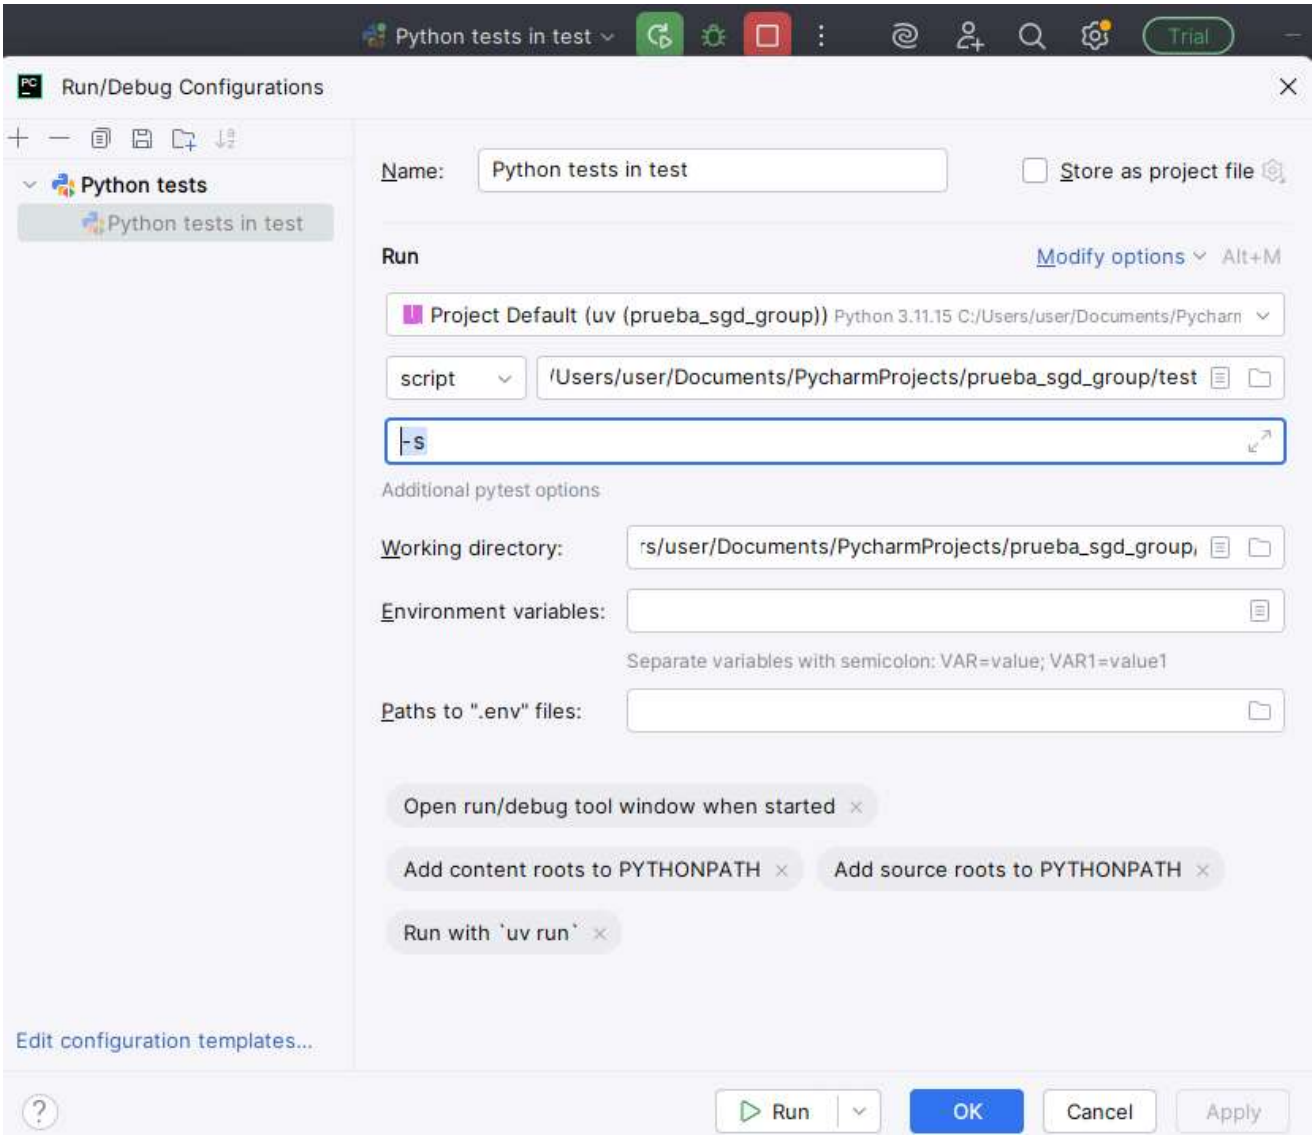


- La clase Test_apartado_5(TestBase) - Valida los datos de entrada de manera acorde a los requisitos expuestos en el enunciado:

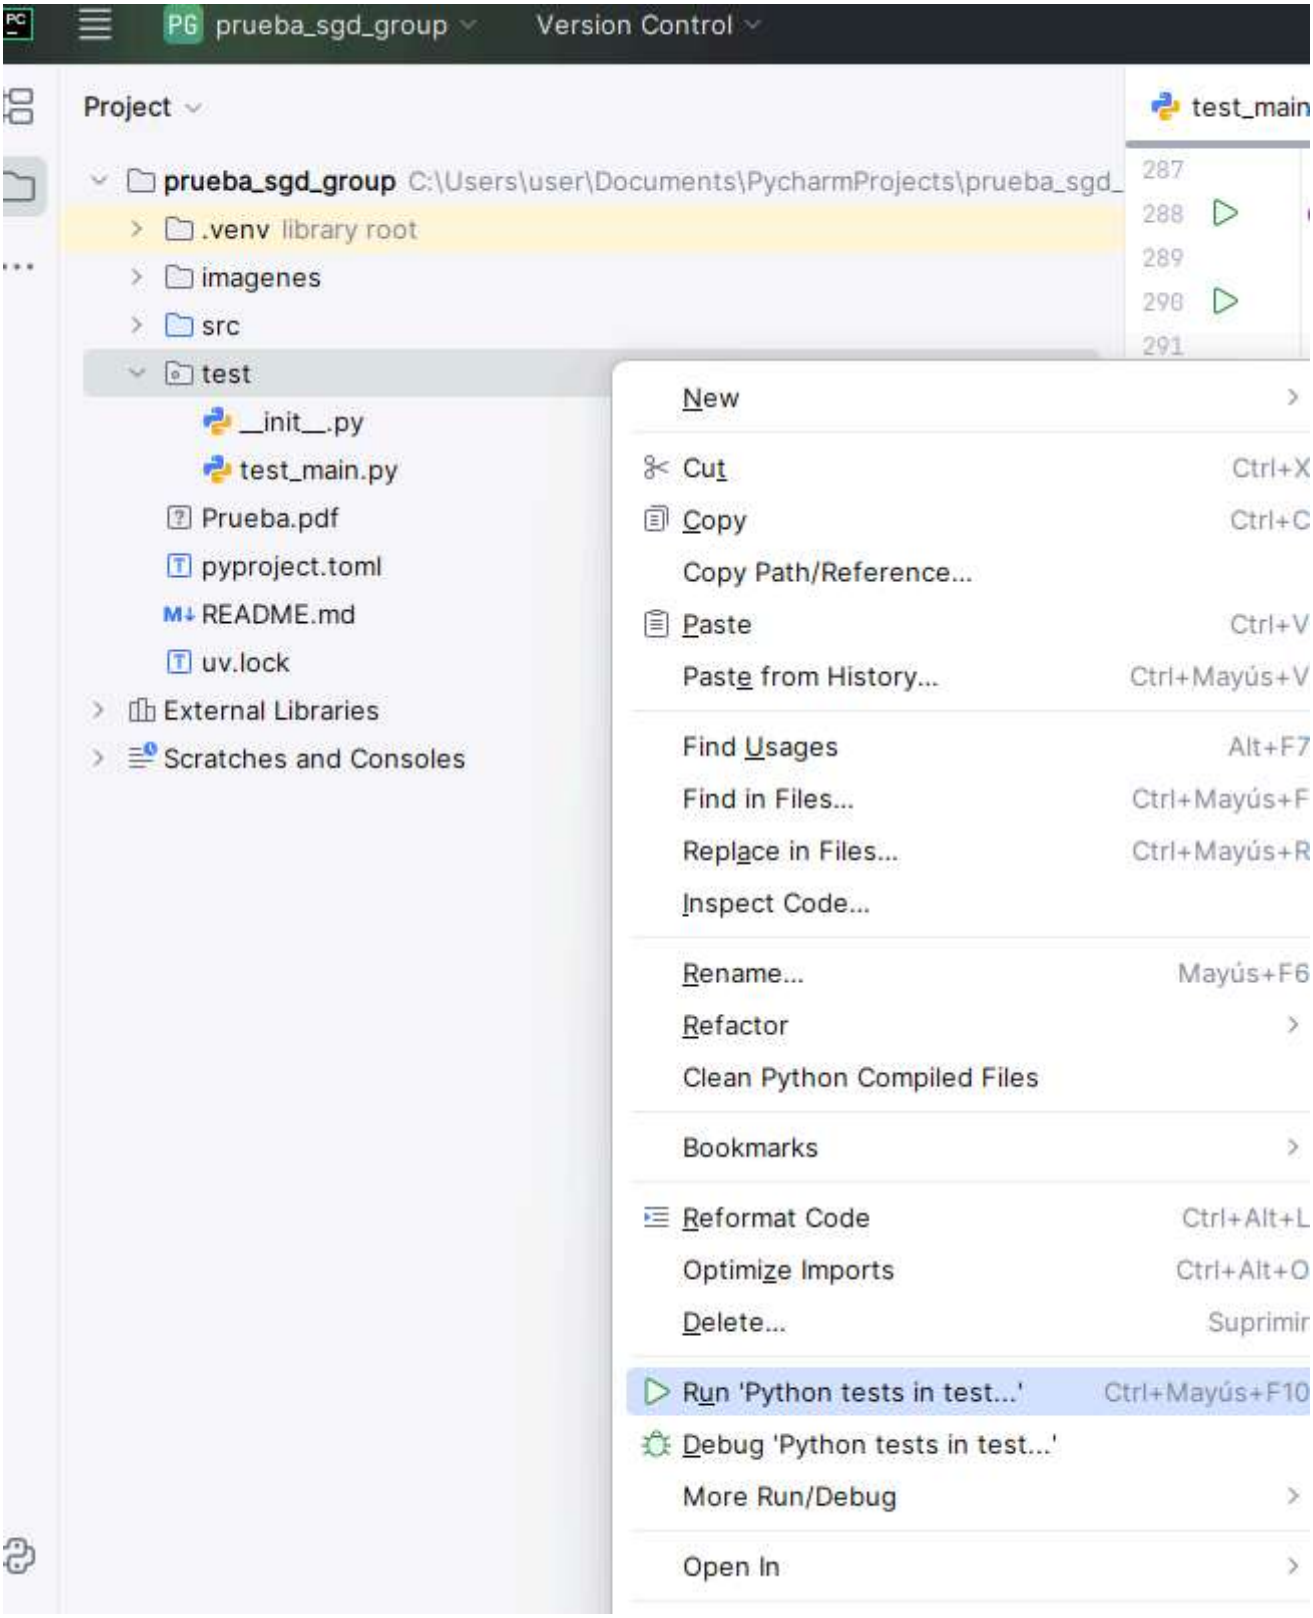


Ejecución de las pruebas de la funcionalidad desarrollada

Evita que PyTest oculte la salida estándar poniendo este parámetro:



Y lanza los tests:


PG prueba_sgd_group
Version Control
Project
test_main
prueba_sgd_group C:\Users\user\Documents\PycharmProjects\prueba_sgd_
.venv library root
imagenes
src
test
__init__.py
test_main.py
Prueba.pdf
pyproject.toml
README.md
uv.lock
External Libraries
Scratches and Consoles
287
288
289
290
291
New
Cut Ctrl+X
Copy Ctrl+C
Copy Path/Reference...
Paste Ctrl+V
Paste from History... Ctrl+Mayús+V
Find Usages Alt+F7
Find in Files... Ctrl+Mayús+F
Replace in Files... Ctrl+Mayús+R
Inspect Code...
Rename... Mayús+F6
Refactor
Clean Python Compiled Files
Bookmarks
Reformat Code Ctrl+Alt+L
Optimize Imports Ctrl+Alt+O
Delete... Suprimir
Run 'Python tests in test...' Ctrl+Mayús+F10
Debug 'Python tests in test...'
More Run/Debug
Open In



Alternativamente puede utilizarse uv para lanzar los tests desde línea de comando:

```
user@DESKTOP-SCNMK3I MINGW64 ~/Documents/PycharmProjects/prueba_sgd_group
Thu Aug 27 10:44:51
$ uv run pytest test/test_main.py -s
============================================================================
platform win32 -- Python 3.13.15, pytest-9.1.1, pluggy-1.6.0
rootdir: C:\Users\user\Documents\PycharmProjects\prueba_sgd_group
configfile: pyproject.toml
plugins: anyio-4.14.2, cov-7.1.0, mock-3.15.1
collected 7 items

test\test_main.py :: loading settings :: url = jar:file:/C:/Users/user/Document
Ivy Default Cache set to: C:\Users\user\.ivy2\cache
The jars for the packages stored in: C:\Users\user\.ivy2\jars
io.delta#delta-spark_2.12 added as a dependency
org.apache.hadoop#hadoop-aws added as a dependency
com.amazonaws#aws-java-sdk-bundle added as a dependency
:: resolving dependencies :: org.apache.spark#spark-submit-parent-f3b145f8-aa5a
        confs: [default]
        found io.delta#delta-spark_2.12;3.2.0 in central
        found io.delta#delta-storage;3.2.0 in central
        found org.antlr#antlr4-runtime;4.9.3 in central
        found org.apache.hadoop#hadoop-aws;3.3.4 in central
        found com.amazonaws#aws-java-sdk-bundle;1.12.262 in central
        found org.wildfly.openssl#wildfly-openssl;1.0.7.Final in central
:: resolution report :: resolve 167ms :: artifacts dl 16ms
        :: modules in use:
        com.amazonaws#aws-java-sdk-bundle;1.12.262 from central in [default]
        io.delta#delta-spark_2.12;3.2.0 from central in [default]
        io.delta#delta-storage;3.2.0 from central in [default]
        org.antlr#antlr4-runtime;4.9.3 from central in [default]
        org.apache.hadoop#hadoop-aws;3.3.4 from central in [default]
        org.wildfly.openssl#wildfly-openssl;1.0.7.Final from central in [defaul
        ---------------------------------------------------------------------
        |                  |            modules            ||   artifacts   |
        |       conf       | number| search|dwnlded|evicted|| number|dwnlded|
        ---------------------------------------------------------------------
        |      default     |   6   |   0   |   0   |   0   ||   6   |   0   |
```

```
        ---------------------------------------------------------------------
:: retrieving :: org.apache.spark#spark-submit-parent-f3b145f8-aa5a-449e-82d0-fl
        confs: [default]
        0 artifacts copied, 6 already retrieved (0kB/18ms)
Setting default log level to "WARN".
To adjust logging level use sc.setLogLevel(newLevel). For SparkR, use setLogLev


         ================================
         INFORME overwrite, append y merge
         ================================

 [+] Año procesado: 2024 | Total registros: 15410
1. Salida tipo 'file' con save_mode overwrite (ubicación de salida: /data/demo/
 [+] [OVERWRITE] Directorio 'C:\Users\user\Documents\PycharmProjects\prueba_sgd_
2. Salida tipo file con save_mode append y particionado (ubicació: /data/demo/ou
 [+] [APPEND] Directorio 'C:\Users\user\Documents\PycharmProjects\prueba_sgd_gr
3. Salida tipo table en DynamoDB (modo append)
La tabla demo tiene 6524 elementos insertados en modo append.
4. Salida tipo table en DynamoDB (modos merge)
La tabla raw_demo tiene 7291 elementos insertados en modo merge.
================================================

...
...
...
```

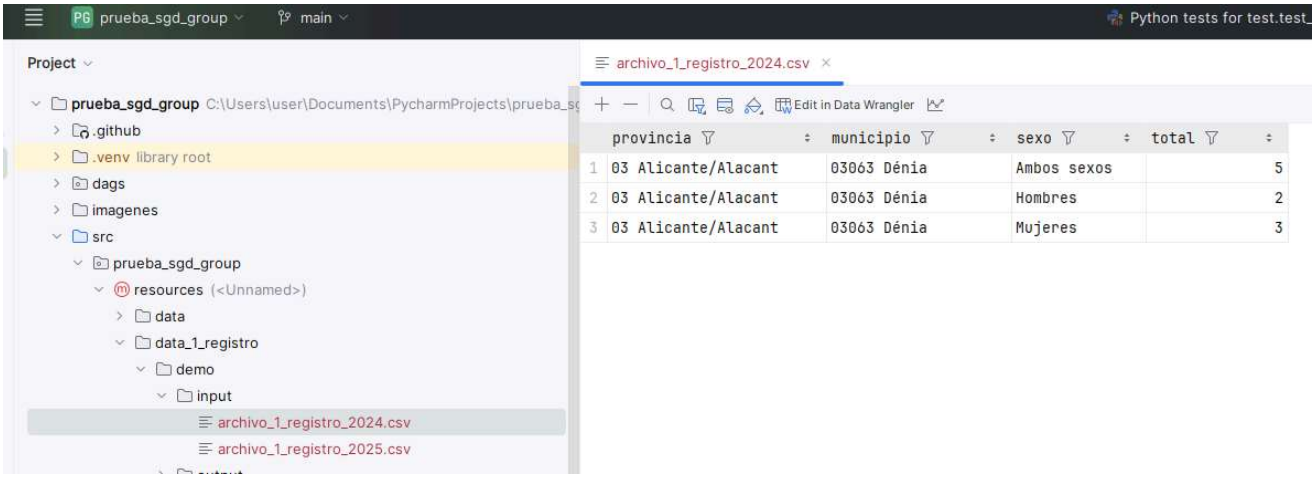
Diferencias entre el comportamiento entre los almacenamientos overwrite, append y merge

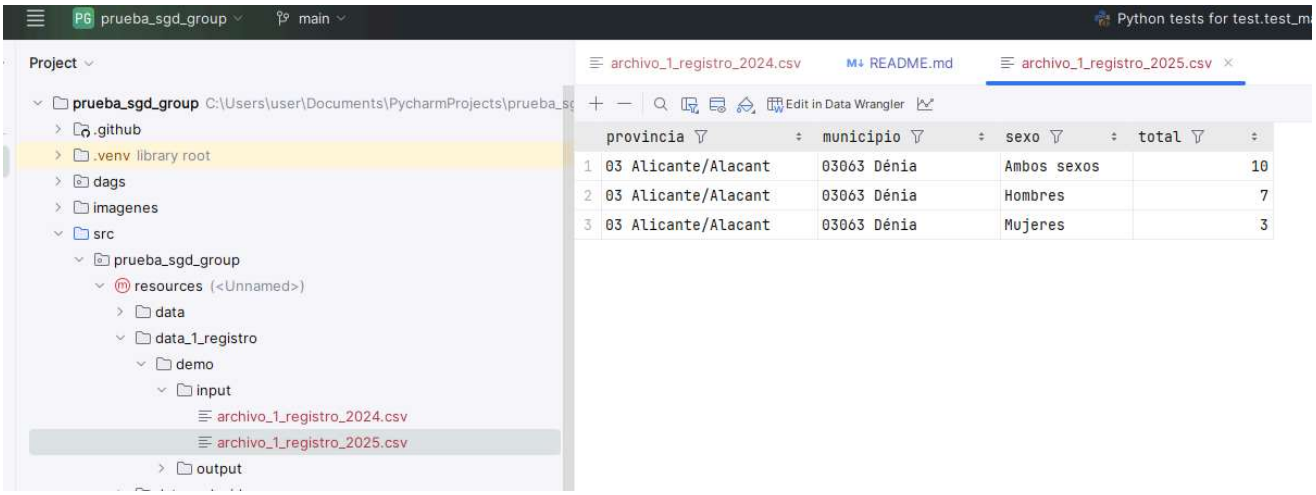
Para ilustrar mejor este comportamiento, adicionalmente al test genérico he preparado un par de tests con una fracción de los datos entrada csv que vemos a continuación.

test_informe_overwrite_append_merge_CSV_1_registro

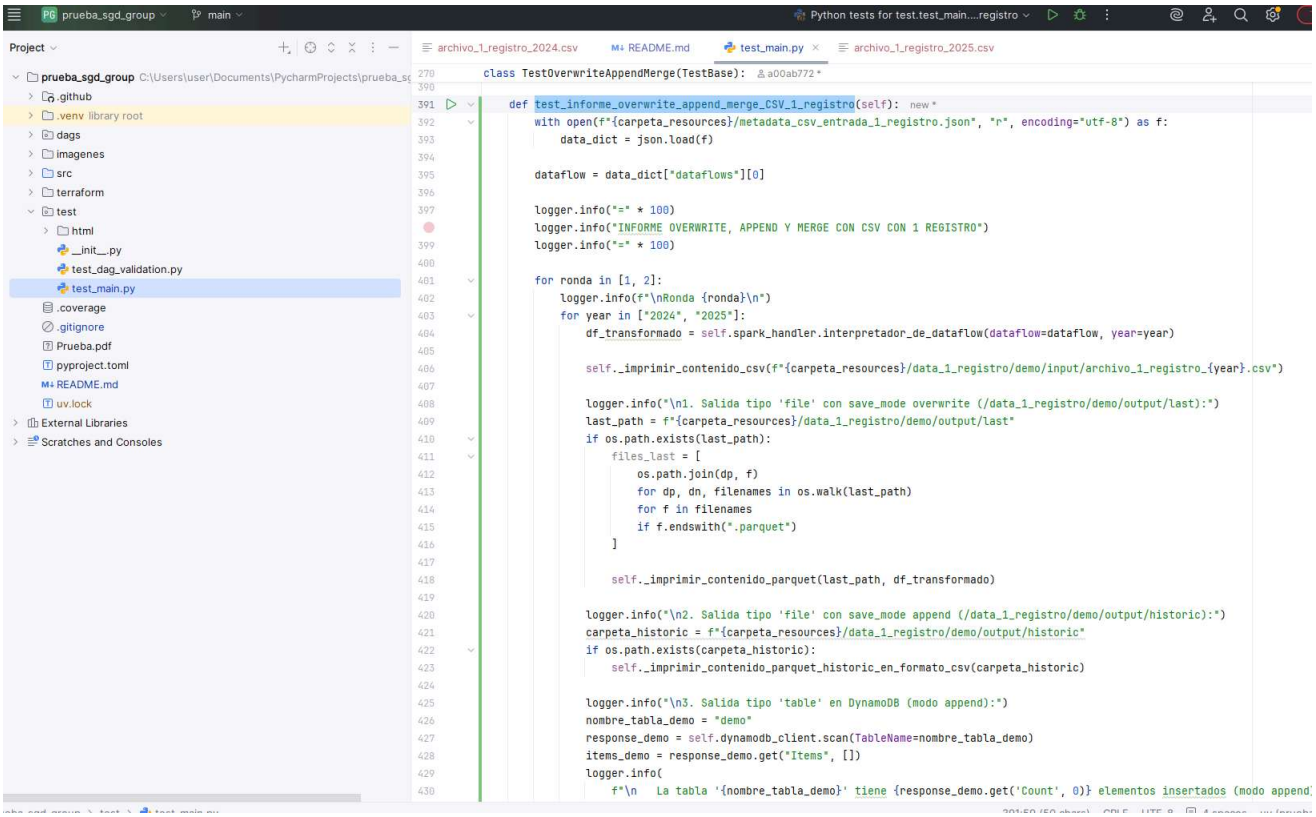
Más que un registro debería de llamarse algo como lo más simple posible; uso sólo una provincia y una línea por sexo, incluída la agregación.

Estos son los datos de entrada:



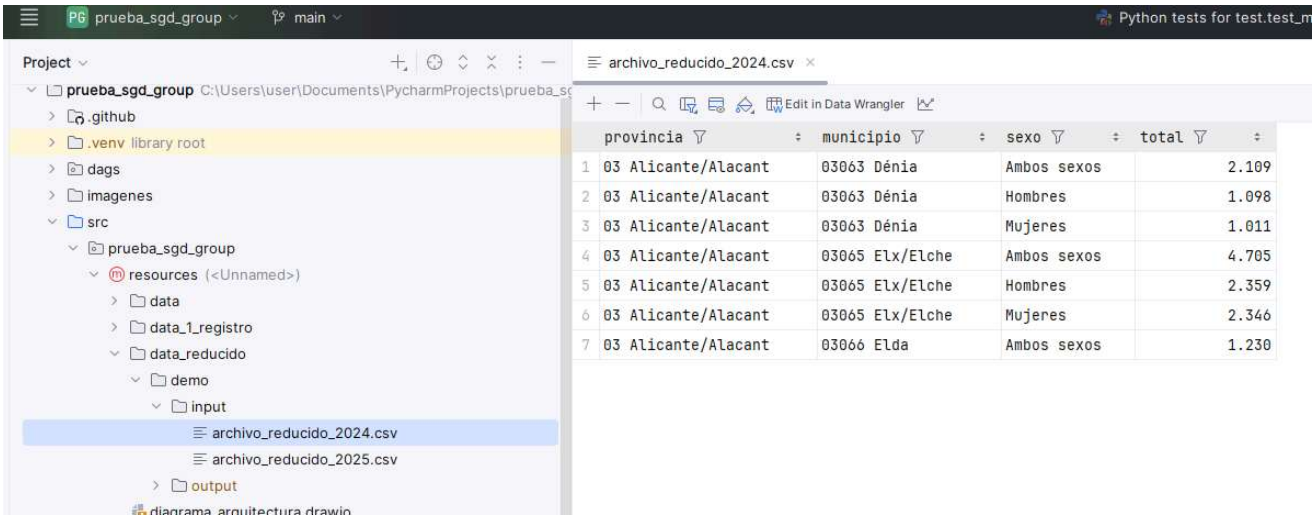


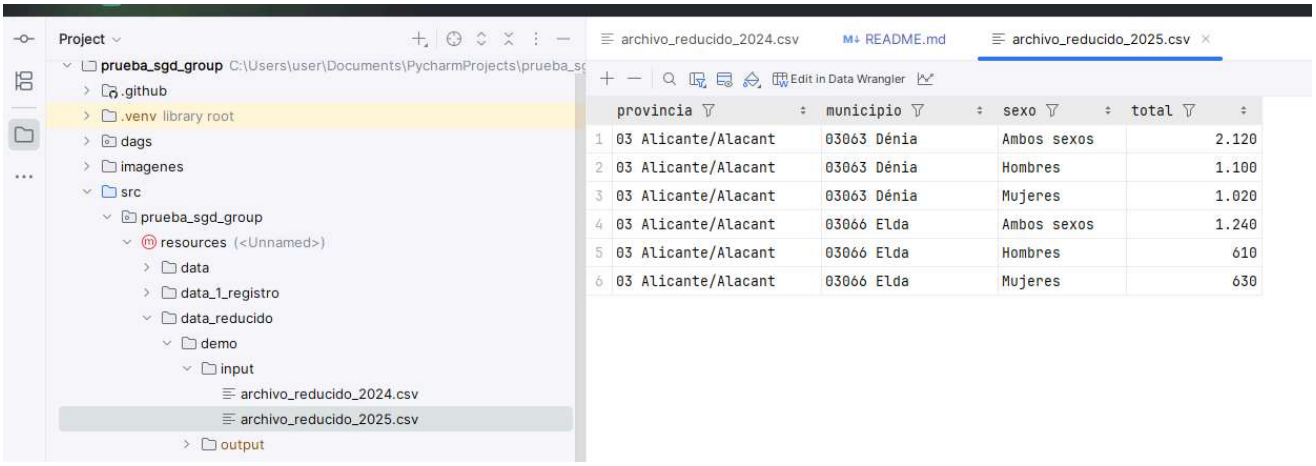
Este es el test en cuestión:



test_informe_overwrite_append_merge_CSV_REDUCIDOS

Los datos de entrada son estos:





Este es el test en cuestión:

Resultado de la ejecución

```
================================================================================
INFORME OVERWRITE, APPEND Y MERGE CON CSV CON 1 REGISTRO
================================================================================

        A continuación vamos a leer los archivos csv de entrada de 2024 y 2025 
        salidas overwrite, append y merge que hemos obtenido.


Ronda 1

--------------------------------------------------------------------------------

[+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_sg

    Contenido del archivo C:\Users\user\Documents\PycharmProjects\prueba_sgd_gr

    provincia          | municipio    | sexo         | total
    -------------------+--------------+--------------+------
```

```
    03 Alicante/Alacant | 03063 Dénia | Ambos sexos | 5
    03 Alicante/Alacant | 03063 Dénia | Hombres     | 2
    03 Alicante/Alacant | 03063 Dénia | Mujeres     | 3
-------------------------------------------------------------------------------

1. Salida tipo 'file' con save_mode overwrite (/data_1_registro/demo/output/last

   Contenido actual de las filas en el Parquet (2 registros):
    provincia           | municipio   | sexo    | total_ambos_sexos | load_date
    --------------------+-------------+---------+-------------------+----------
    03 Alicante/Alacant | 03063 Dénia | Mujeres | 3                 | 2026-08-24
    03 Alicante/Alacant | 03063 Dénia | Hombres | 2                 | 2026-08-24

2. Salida tipo 'file' con save_mode append (/data_1_registro/demo/output/histor

    Contenido unificado de todos los CSVs almacenados en la carpeta parquet 'his

    provincia           | municipio   | sexo    | total_ambos_sexos
    --------------------+-------------+---------+------------------
    03 Alicante/Alacant | 03063 Dénia | Mujeres | 3
    03 Alicante/Alacant | 03063 Dénia | Hombres | 2
-------------------------------------------------------------------------------

3. Salida tipo 'table' en DynamoDB (modo append):

   La tabla 'demo' tiene 2 elementos insertados (modo append):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé

4. Salida tipo 'table' en DynamoDB (modo merge):

   La tabla 'raw_demo' tiene 2 elementos insertados (modo merge):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé

===============================================================================
-------------------------------------------------------------------------------

[+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_s

    Contenido del archivo C:\Users\user\Documents\PycharmProjects\prueba_sgd_gr

    provincia           | municipio   | sexo        | total
    --------------------+-------------+-------------+------
    03 Alicante/Alacant | 03063 Dénia | Ambos sexos | 10
    03 Alicante/Alacant | 03063 Dénia | Hombres     | 7
    03 Alicante/Alacant | 03063 Dénia | Mujeres     | 3
-------------------------------------------------------------------------------

1. Salida tipo 'file' con save_mode overwrite (/data_1_registro/demo/output/last

   Contenido actual de las filas en el Parquet (2 registros):
    provincia           | municipio   | sexo    | total_ambos_sexos | load_date
```

```
    --------------------+-------------+---------+-------------------+----------
    03 Alicante/Alacant | 03063 Dénia | Mujeres | 3                 | 2026-08-2
    03 Alicante/Alacant | 03063 Dénia | Hombres | 7                 | 2026-08-2

2. Salida tipo 'file' con save_mode append (/data_1_registro/demo/output/histor

    Contenido unificado de todos los CSVs almacenados en la carpeta parquet 'his

    provincia           | municipio   | sexo    | total_ambos_sexos
    --------------------+-------------+---------+------------------
    03 Alicante/Alacant | 03063 Dénia | Mujeres | 3
    03 Alicante/Alacant | 03063 Dénia | Hombres | 2
    03 Alicante/Alacant | 03063 Dénia | Mujeres | 3
    03 Alicante/Alacant | 03063 Dénia | Hombres | 7
-------------------------------------------------------------------------------

3. Salida tipo 'table' en DynamoDB (modo append):

   La tabla 'demo' tiene 2 elementos insertados (modo append):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé

4. Salida tipo 'table' en DynamoDB (modo merge):

   La tabla 'raw_demo' tiene 2 elementos insertados (modo merge):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé

===============================================================================

Ronda 2

-------------------------------------------------------------------------------

[+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_s

    Contenido del archivo C:\Users\user\Documents\PycharmProjects\prueba_sgd_gr

    provincia           | municipio   | sexo        | total
    --------------------+-------------+-------------+------
    03 Alicante/Alacant | 03063 Dénia | Ambos sexos | 5
    03 Alicante/Alacant | 03063 Dénia | Hombres     | 2
    03 Alicante/Alacant | 03063 Dénia | Mujeres     | 3
-------------------------------------------------------------------------------

1. Salida tipo 'file' con save_mode overwrite (/data_1_registro/demo/output/las

   Contenido actual de las filas en el Parquet (2 registros):
    provincia           | municipio   | sexo    | total_ambos_sexos | load_date
    --------------------+-------------+---------+-------------------+----------
    03 Alicante/Alacant | 03063 Dénia | Mujeres | 3                 | 2026-08-2
    03 Alicante/Alacant | 03063 Dénia | Hombres | 2                 | 2026-08-2
```

```
2. Salida tipo 'file' con save_mode append (/data_1_registro/demo/output/histor

    Contenido unificado de todos los CSVs almacenados en la carpeta parquet 'his

    provincia           | municipio   | sexo     | total_ambos_sexos
    --------------------+-------------+----------+------------------
    03 Alicante/Alacant | 03063 Dénia | Mujeres  | 3
    03 Alicante/Alacant | 03063 Dénia | Hombres  | 2
    03 Alicante/Alacant | 03063 Dénia | Mujeres  | 3
    03 Alicante/Alacant | 03063 Dénia | Hombres  | 7
    03 Alicante/Alacant | 03063 Dénia | Mujeres  | 3
    03 Alicante/Alacant | 03063 Dénia | Hombres  | 2
--------------------------------------------------------------------------------

3. Salida tipo 'table' en DynamoDB (modo append):

   La tabla 'demo' tiene 2 elementos insertados (modo append):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé

4. Salida tipo 'table' en DynamoDB (modo merge):

   La tabla 'raw_demo' tiene 2 elementos insertados (modo merge):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé

================================================================================
--------------------------------------------------------------------------------

[+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_s

    Contenido del archivo C:\Users\user\Documents\PycharmProjects\prueba_sgd_gr

    provincia           | municipio   | sexo         | total
    --------------------+-------------+--------------+------
    03 Alicante/Alacant | 03063 Dénia | Ambos sexos  | 10
    03 Alicante/Alacant | 03063 Dénia | Hombres      | 7
    03 Alicante/Alacant | 03063 Dénia | Mujeres      | 3
--------------------------------------------------------------------------------

1. Salida tipo 'file' con save_mode overwrite (/data_1_registro/demo/output/las

   Contenido actual de las filas en el Parquet (2 registros):
    provincia           | municipio   | sexo     | total_ambos_sexos | load_date
    --------------------+-------------+----------+-------------------+----------
    03 Alicante/Alacant | 03063 Dénia | Mujeres  | 3                 | 2026-08-2
    03 Alicante/Alacant | 03063 Dénia | Hombres  | 7                 | 2026-08-2

2. Salida tipo 'file' con save_mode append (/data_1_registro/demo/output/histor

    Contenido unificado de todos los CSVs almacenados en la carpeta parquet 'his

    provincia           | municipio   | sexo     | total_ambos_sexos
```

```
    --------------------+-------------+---------+-----------------
    03 Alicante/Alacant | 03063 Dénia | Mujeres | 3
    03 Alicante/Alacant | 03063 Dénia | Hombres | 2
    03 Alicante/Alacant | 03063 Dénia | Mujeres | 3
    03 Alicante/Alacant | 03063 Dénia | Hombres | 7
    03 Alicante/Alacant | 03063 Dénia | Mujeres | 3
    03 Alicante/Alacant | 03063 Dénia | Hombres | 7
    03 Alicante/Alacant | 03063 Dénia | Mujeres | 3
    03 Alicante/Alacant | 03063 Dénia | Hombres | 2
--------------------------------------------------------------------------------

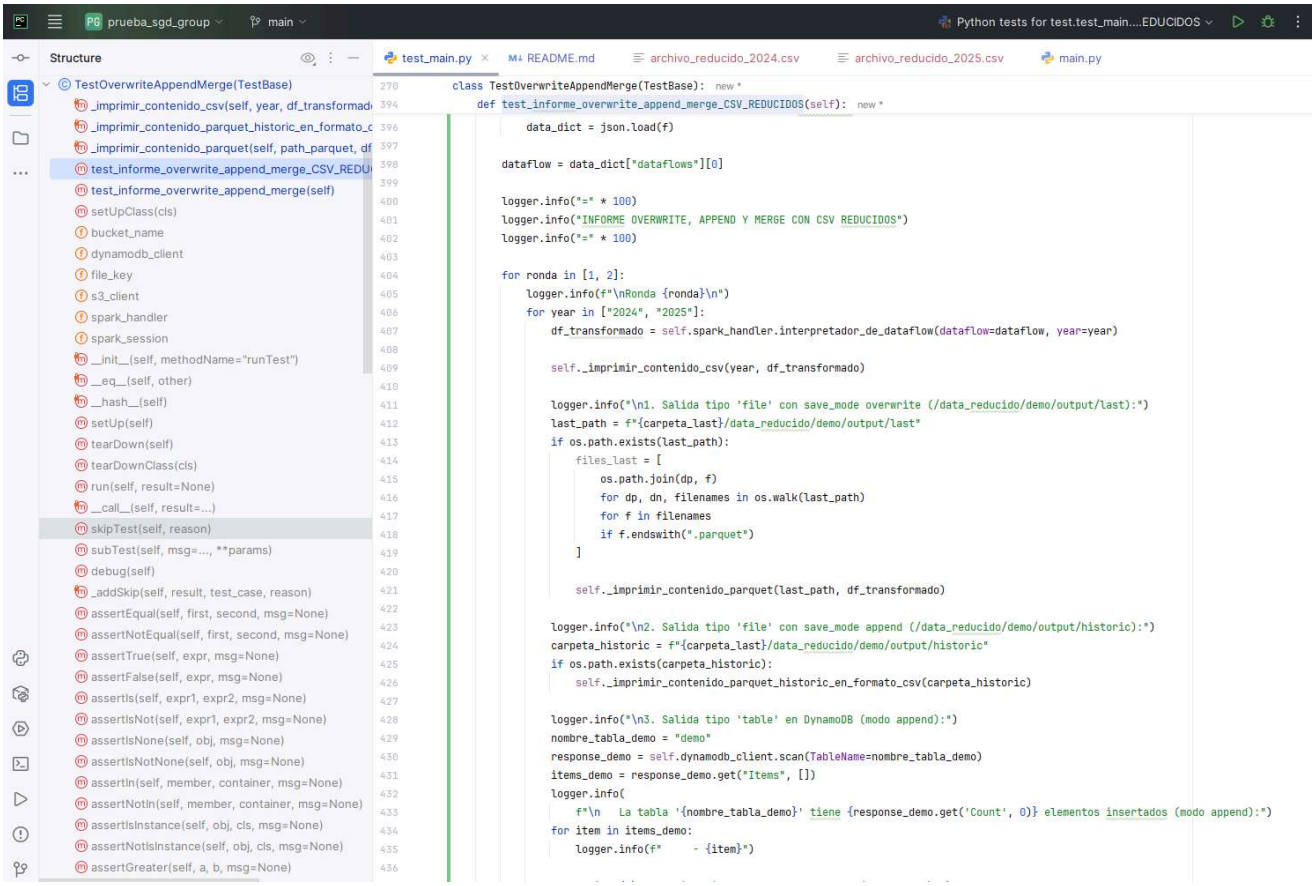
3. Salida tipo 'table' en DynamoDB (modo append):

   La tabla 'demo' tiene 2 elementos insertados (modo append):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé

4. Salida tipo 'table' en DynamoDB (modo merge):

   La tabla 'raw_demo' tiene 2 elementos insertados (modo merge):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé

================================================================================
```



Resultado de la ejecución

```
================================================================================
INFORME OVERWRITE, APPEND Y MERGE CON CSV REDUCIDOS
================================================================================


        A continuación vamos a leer los archivos csv de entrada de 2024 y 2025 
        salidas overwrite, append y merge que hemos obtenido.


Ronda 1

--------------------------------------------------------------------------------

[+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_sg

    Contenido del archivo C:\Users\user\Documents\PycharmProjects\prueba_sgd_gr

    provincia          | municipio       | sexo        | total
    -------------------+-----------------+-------------+------
    03 Alicante/Alacant | 03063 Dénia     | Ambos sexos | 2.109
    03 Alicante/Alacant | 03063 Dénia     | Hombres     | 1.098
    03 Alicante/Alacant | 03063 Dénia     | Mujeres     | 1.011
    03 Alicante/Alacant | 03065 Elx/Elche | Ambos sexos | 4.705
    03 Alicante/Alacant | 03065 Elx/Elche | Hombres     | 2.359
    03 Alicante/Alacant | 03065 Elx/Elche | Mujeres     | 2.346
    03 Alicante/Alacant | 03066 Elda      | Ambos sexos | 1.230
--------------------------------------------------------------------------------

1. Salida tipo 'file' con save_mode overwrite (/data_reducido/demo/output/last)

   Contenido actual de las filas en el Parquet (4 registros):
    provincia          | municipio       | sexo    | total_ambos_sexos | load_
    -------------------+-----------------+---------+-------------------+------
    03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1011              | 2026-0
    03 Alicante/Alacant | 03065 Elx/Elche | Hombres | 2359              | 2026-0
    03 Alicante/Alacant | 03063 Dénia     | Hombres | 1098              | 2026-0
    03 Alicante/Alacant | 03065 Elx/Elche | Mujeres | 2346              | 2026-0

2. Salida tipo 'file' con save_mode append (/data_reducido/demo/output/historic

    Contenido unificado de todos los CSVs almacenados en la carpeta parquet 'his

    provincia          | municipio       | sexo    | total_ambos_sexos
    -------------------+-----------------+---------+------------------
    03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1011
    03 Alicante/Alacant | 03065 Elx/Elche | Hombres | 2359
    03 Alicante/Alacant | 03063 Dénia     | Hombres | 1098
    03 Alicante/Alacant | 03065 Elx/Elche | Mujeres | 2346
--------------------------------------------------------------------------------

3. Salida tipo 'table' en DynamoDB (modo append):
```

```
   La tabla 'demo' tiene 4 elementos insertados (modo append):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El

4. Salida tipo 'table' en DynamoDB (modo merge):

   La tabla 'raw_demo' tiene 4 elementos insertados (modo merge):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El

================================================================================
--------------------------------------------------------------------------------

[+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_sg

    Contenido del archivo C:\Users\user\Documents\PycharmProjects\prueba_sgd_gr

    provincia          | municipio    | sexo        | total
    -------------------+--------------+-------------+------
    03 Alicante/Alacant | 03063 Dénia | Ambos sexos | 2.120
    03 Alicante/Alacant | 03063 Dénia | Hombres     | 1.100
    03 Alicante/Alacant | 03063 Dénia | Mujeres     | 1.020
    03 Alicante/Alacant | 03066 Elda   | Ambos sexos | 1.240
    03 Alicante/Alacant | 03066 Elda   | Hombres     | 610
    03 Alicante/Alacant | 03066 Elda   | Mujeres     | 630
--------------------------------------------------------------------------------

1. Salida tipo 'file' con save_mode overwrite (/data_reducido/demo/output/last)

   Contenido actual de las filas en el Parquet (4 registros):
    provincia          | municipio    | sexo    | total_ambos_sexos | load_date
    -------------------+--------------+---------+-------------------+----------
    03 Alicante/Alacant | 03066 Elda   | Mujeres | 630               | 2026-08-24
    03 Alicante/Alacant | 03063 Dénia | Mujeres | 1020              | 2026-08-24
    03 Alicante/Alacant | 03066 Elda   | Hombres | 610               | 2026-08-24
    03 Alicante/Alacant | 03063 Dénia | Hombres | 1100              | 2026-08-24

2. Salida tipo 'file' con save_mode append (/data_reducido/demo/output/historic

    Contenido unificado de todos los CSVs almacenados en la carpeta parquet 'his

    provincia          | municipio       | sexo    | total_ambos_sexos
    -------------------+-----------------+---------+------------------
    03 Alicante/Alacant | 03066 Elda      | Mujeres | 630
    03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1020
    03 Alicante/Alacant | 03066 Elda      | Hombres | 610
    03 Alicante/Alacant | 03063 Dénia     | Hombres | 1100
    03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1011
    03 Alicante/Alacant | 03065 Elx/Elche | Hombres | 2359
```

```
    03 Alicante/Alacant | 03063 Dénia     | Hombres | 1098
    03 Alicante/Alacant | 03065 Elx/Elche | Mujeres | 2346
-------------------------------------------------------------------------------

3. Salida tipo 'table' en DynamoDB (modo append):

   La tabla 'demo' tiene 6 elementos insertados (modo append):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066 El

4. Salida tipo 'table' en DynamoDB (modo merge):

   La tabla 'raw_demo' tiene 6 elementos insertados (modo merge):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066 El

===============================================================================

Ronda 2

-------------------------------------------------------------------------------

[+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_s

    Contenido del archivo C:\Users\user\Documents\PycharmProjects\prueba_sgd_gr

    provincia          | municipio       | sexo        | total
    -------------------+-----------------+-------------+------
    03 Alicante/Alacant | 03063 Dénia     | Ambos sexos | 2.109
    03 Alicante/Alacant | 03063 Dénia     | Hombres     | 1.098
    03 Alicante/Alacant | 03063 Dénia     | Mujeres     | 1.011
    03 Alicante/Alacant | 03065 Elx/Elche | Ambos sexos | 4.705
    03 Alicante/Alacant | 03065 Elx/Elche | Hombres     | 2.359
    03 Alicante/Alacant | 03065 Elx/Elche | Mujeres     | 2.346
    03 Alicante/Alacant | 03066 Elda      | Ambos sexos | 1.230
-------------------------------------------------------------------------------

1. Salida tipo 'file' con save_mode overwrite (/data_reducido/demo/output/last)

   Contenido actual de las filas en el Parquet (4 registros):
    provincia          | municipio       | sexo    | total_ambos_sexos | load_
    -------------------+-----------------+---------+-------------------+------
    03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1011              | 2026-
    03 Alicante/Alacant | 03065 Elx/Elche | Hombres | 2359              | 2026-
    03 Alicante/Alacant | 03063 Dénia     | Hombres | 1098              | 2026-
```

```
    03 Alicante/Alacant | 03065 Elx/Elche | Mujeres | 2346              | 2026-0

2. Salida tipo 'file' con save_mode append (/data_reducido/demo/output/historic)

    Contenido unificado de todos los CSVs almacenados en la carpeta parquet 'his

    provincia           | municipio       | sexo    | total_ambos_sexos
    --------------------+-----------------+---------+------------------
    03 Alicante/Alacant | 03066 Elda      | Mujeres | 630
    03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1020
    03 Alicante/Alacant | 03066 Elda      | Hombres | 610
    03 Alicante/Alacant | 03063 Dénia     | Hombres | 1100
    03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1011
    03 Alicante/Alacant | 03065 Elx/Elche | Hombres | 2359
    03 Alicante/Alacant | 03063 Dénia     | Hombres | 1098
    03 Alicante/Alacant | 03065 Elx/Elche | Mujeres | 2346
    03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1011
    03 Alicante/Alacant | 03065 Elx/Elche | Hombres | 2359
    03 Alicante/Alacant | 03063 Dénia     | Hombres | 1098
    03 Alicante/Alacant | 03065 Elx/Elche | Mujeres | 2346
-------------------------------------------------------------------------------

3. Salida tipo 'table' en DynamoDB (modo append):

   La tabla 'demo' tiene 6 elementos insertados (modo append):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066 El

4. Salida tipo 'table' en DynamoDB (modo merge):

   La tabla 'raw_demo' tiene 6 elementos insertados (modo merge):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066 El

================================================================================
--------------------------------------------------------------------------------

[+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_sg

    Contenido del archivo C:\Users\user\Documents\PycharmProjects\prueba_sgd_gr

    provincia           | municipio   | sexo        | total
    --------------------+-------------+-------------+------
    03 Alicante/Alacant | 03063 Dénia | Ambos sexos | 2.120
    03 Alicante/Alacant | 03063 Dénia | Hombres     | 1.100
```

```
 03 Alicante/Alacant | 03063 Dénia | Mujeres     | 1.020
 03 Alicante/Alacant | 03066 Elda  | Ambos sexos | 1.240
 03 Alicante/Alacant | 03066 Elda  | Hombres     | 610
 03 Alicante/Alacant | 03066 Elda  | Mujeres     | 630
-------------------------------------------------------------------------------

1. Salida tipo 'file' con save_mode overwrite (/data_reducido/demo/output/last)

   Contenido actual de las filas en el Parquet (4 registros):
 provincia           | municipio   | sexo    | total_ambos_sexos | load_date
 --------------------+-------------+---------+-------------------+----------
 03 Alicante/Alacant | 03066 Elda  | Mujeres | 630               | 2026-08-24
 03 Alicante/Alacant | 03063 Dénia | Mujeres | 1020              | 2026-08-24
 03 Alicante/Alacant | 03066 Elda  | Hombres | 610               | 2026-08-24
 03 Alicante/Alacant | 03063 Dénia | Hombres | 1100              | 2026-08-24

2. Salida tipo 'file' con save_mode append (/data_reducido/demo/output/historic)

 Contenido unificado de todos los CSVs almacenados en la carpeta parquet 'his

 provincia           | municipio       | sexo    | total_ambos_sexos
 --------------------+-----------------+---------+------------------
 03 Alicante/Alacant | 03066 Elda      | Mujeres | 630
 03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1020
 03 Alicante/Alacant | 03066 Elda      | Hombres | 610
 03 Alicante/Alacant | 03063 Dénia     | Hombres | 1100
 03 Alicante/Alacant | 03066 Elda      | Mujeres | 630
 03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1020
 03 Alicante/Alacant | 03066 Elda      | Hombres | 610
 03 Alicante/Alacant | 03063 Dénia     | Hombres | 1100
 03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1011
 03 Alicante/Alacant | 03065 Elx/Elche | Hombres | 2359
 03 Alicante/Alacant | 03063 Dénia     | Hombres | 1098
 03 Alicante/Alacant | 03065 Elx/Elche | Mujeres | 2346
 03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1011
 03 Alicante/Alacant | 03065 Elx/Elche | Hombres | 2359
 03 Alicante/Alacant | 03063 Dénia     | Hombres | 1098
 03 Alicante/Alacant | 03065 Elx/Elche | Mujeres | 2346
-------------------------------------------------------------------------------

3. Salida tipo 'table' en DynamoDB (modo append):

   La tabla 'demo' tiene 6 elementos insertados (modo append):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066 El

4. Salida tipo 'table' en DynamoDB (modo merge):

   La tabla 'raw_demo' tiene 6 elementos insertados (modo merge):
```

```
- {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
- {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
- {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
- {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
- {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066 El
- {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066 El
```

```
================================================================================
```

A partir de las salidas obtenidas en las dos rondas de ejecución con los mismos datos de entrada, las conclusiones sobre cada tipo de almacenamiento se ilustran claramente con los siguientes datos reales:

A partir de la ejecución completa en dos rondas proporcionada, las conclusiones clave sobre el comportamiento de cada estrategia de almacenamiento son las siguientes:

1. **Salida tipo 'file' con save_mode overwrite (/data_reducido/demo/output/last)**

El modo overwrite reemplaza por completo el contenido anterior en cada ejecución o iteración de año.

Esto queda patente en el siguente detalle donde se ve la salida que hemos obtenido, vamos por partes; este es el parquet resultante al terminar de procesar el año 2024:

```
================================================================================
INFORME OVERWRITE, APPEND Y MERGE CON CSV REDUCIDOS
================================================================================


        A continuación vamos a leer los archivos csv de entrada de 2024 y 2025 
        salidas overwrite, append y merge que hemos obtenido.


Ronda 1

--------------------------------------------------------------------------------

[+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_s

    Contenido del archivo C:\Users\user\Documents\PycharmProjects\prueba_sgd_gr

    provincia          | municipio       | sexo        | total
    -------------------+-----------------+-------------+------
    03 Alicante/Alacant | 03063 Dénia     | Ambos sexos | 2.109
    03 Alicante/Alacant | 03063 Dénia     | Hombres     | 1.098
    03 Alicante/Alacant | 03063 Dénia     | Mujeres     | 1.011
    03 Alicante/Alacant | 03065 Elx/Elche | Ambos sexos | 4.705
    03 Alicante/Alacant | 03065 Elx/Elche | Hombres     | 2.359
    03 Alicante/Alacant | 03065 Elx/Elche | Mujeres     | 2.346
```

```
    03 Alicante/Alacant | 03066 Elda      | Ambos sexos | 1.230
-------------------------------------------------------------------------------

    ...
1. Salida tipo 'file' con save_mode overwrite (/data_reducido/demo/output/last)

   Contenido actual de las filas en el Parquet (4 registros):
    provincia           | municipio       | sexo     | total_ambos_sexos | load_
    --------------------+-----------------+----------+-------------------+------
    03 Alicante/Alacant | 03063 Dénia     | Mujeres  | 1011              | 2026-
    03 Alicante/Alacant | 03065 Elx/Elche | Hombres  | 2359              | 2026-
    03 Alicante/Alacant | 03063 Dénia     | Hombres  | 1098              | 2026-
    03 Alicante/Alacant | 03065 Elx/Elche | Mujeres  | 2346              | 2026-
    ...
```

y esto es el contenido del parquet alimentado en modo overwrite tras procesar el archivo 2025:

```
Ronda 1

-------------------------------------------------------------------------------
  ...
  [+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_
  ...


1. Salida tipo 'file' con save_mode overwrite (/data_reducido/demo/output/last)

   Contenido actual de las filas en el Parquet (4 registros):
    provincia           | municipio   | sexo     | total_ambos_sexos | load_date
    --------------------+-------------+----------+-------------------+----------
    03 Alicante/Alacant | 03066 Elda  | Mujeres  | 630               | 2026-08-2
    03 Alicante/Alacant | 03063 Dénia | Mujeres  | 1020              | 2026-08-2
    03 Alicante/Alacant | 03066 Elda  | Hombres  | 610               | 2026-08-2
    03 Alicante/Alacant | 03063 Dénia | Hombres  | 1100              | 2026-08-2
```

Observamos lo que se esperaba en la salida obtenida, el modo overwrite ha pulverizado los registros de salida que obtuvimos de 2024, reemplazándolos con los nuevos que hemos obtenido de 2025.

Lo mismo ocurrirá en la siguiente ronda donde leemos de nuevo los archivos de 2024 y 2025:

```
    ...
    ...
Ronda 2
```

```
--------------------------------------------------------------------------------
    ...
[+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_sg

...
1. Salida tipo 'file' con save_mode overwrite (/data_reducido/demo/output/last)

   Contenido actual de las filas en el Parquet (4 registros):
    provincia           | municipio       | sexo    | total_ambos_sexos | load_
    --------------------+-----------------+---------+-------------------+------
    03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1011              | 2026-0
    03 Alicante/Alacant | 03065 Elx/Elche | Hombres | 2359              | 2026-0
    03 Alicante/Alacant | 03063 Dénia     | Hombres | 1098              | 2026-0
    03 Alicante/Alacant | 03065 Elx/Elche | Mujeres | 2346              | 2026-0
    ...
    ...
[+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_sg

...

1. Salida tipo 'file' con save_mode overwrite (/data_reducido/demo/output/last)

   Contenido actual de las filas en el Parquet (4 registros):
    provincia           | municipio    | sexo    | total_ambos_sexos | load_date
    --------------------+--------------+---------+-------------------+----------
    03 Alicante/Alacant | 03066 Elda   | Mujeres | 630               | 2026-08-24
    03 Alicante/Alacant | 03063 Dénia  | Mujeres | 1020              | 2026-08-24
    03 Alicante/Alacant | 03066 Elda   | Hombres | 610               | 2026-08-24
    03 Alicante/Alacant | 03063 Dénia  | Hombres | 1100              | 2026-08-24
```

2. Salida tipo 'file' con save_mode append (/data_reducido/demo/output/historic)

El modo append añade filas de forma acumulativa al final del directorio histórico sin validar duplicados.

La primera ronda tras procesar el archivo de 2024 deja estos cuatro registros en el parquet de histórico:

```
    ...
Ronda 1

--------------------------------------------------------------------------------
    [+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\pruel
    ...

2. Salida tipo 'file' con save_mode append (/data_reducido/demo/output/historic

    Contenido unificado de todos los CSVs almacenados en la carpeta parquet 'his

    provincia           | municipio       | sexo    | total_ambos_sexos
```

```
    --------------------+-----------------+---------+-----------------
    03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1011
    03 Alicante/Alacant | 03065 Elx/Elche | Hombres | 2359
    03 Alicante/Alacant | 03063 Dénia     | Hombres | 1098
    03 Alicante/Alacant | 03065 Elx/Elche | Mujeres | 2346
--------------------------------------------------------------------------------
```

A continuación procesamos el archivo de 2025 y se añaden al parquet de históricos los cuatro registros adicionales resultantes de aplicar la transformación a 2025:

```
    ...
Ronda 1

--------------------------------------------------------------------------------
...
[+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_s
...

2. Salida tipo 'file' con save_mode append (/data_reducido/demo/output/historic

    Contenido unificado de todos los CSVs almacenados en la carpeta parquet 'his

    provincia           | municipio       | sexo    | total_ambos_sexos
    --------------------+-----------------+---------+-----------------
    03 Alicante/Alacant | 03066 Elda      | Mujeres | 630
    03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1020
    03 Alicante/Alacant | 03066 Elda      | Hombres | 610
    03 Alicante/Alacant | 03063 Dénia     | Hombres | 1100
    03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1011
    03 Alicante/Alacant | 03065 Elx/Elche | Hombres | 2359
    03 Alicante/Alacant | 03063 Dénia     | Hombres | 1098
    03 Alicante/Alacant | 03065 Elx/Elche | Mujeres | 2346
--------------------------------------------------------------------------------
```

Seguidamente vemos la ronda 2 donde se procesan de nuevo los mismos archivos; el número total de registros en el parquet `historic` crece a 12 con los registros resultantes de procesar el archivo de 2024, y termina con 16 al procesar el archivo de 2025:

```
    ...
Ronda 2

--------------------------------------------------------------------------------
    ...
[+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_s
    ...

2. Salida tipo 'file' con save_mode append (/data_reducido/demo/output/historic
```

```
    Contenido unificado de todos los CSVs almacenados en la carpeta parquet 'his

    provincia           | municipio       | sexo    | total_ambos_sexos
    --------------------+-----------------+---------+------------------
    03 Alicante/Alacant | 03066 Elda      | Mujeres | 630
    03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1020
    03 Alicante/Alacant | 03066 Elda      | Hombres | 610
    03 Alicante/Alacant | 03063 Dénia     | Hombres | 1100
    03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1011
    03 Alicante/Alacant | 03065 Elx/Elche | Hombres | 2359
    03 Alicante/Alacant | 03063 Dénia     | Hombres | 1098
    03 Alicante/Alacant | 03065 Elx/Elche | Mujeres | 2346
    03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1011
    03 Alicante/Alacant | 03065 Elx/Elche | Hombres | 2359
    03 Alicante/Alacant | 03063 Dénia     | Hombres | 1098
    03 Alicante/Alacant | 03065 Elx/Elche | Mujeres | 2346
-------------------------------------------------------------------------------

    ...
[+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_s
    ...

2. Salida tipo 'file' con save_mode append (/data_reducido/demo/output/historic

    Contenido unificado de todos los CSVs almacenados en la carpeta parquet 'his

    provincia           | municipio       | sexo    | total_ambos_sexos
    --------------------+-----------------+---------+------------------
    03 Alicante/Alacant | 03066 Elda      | Mujeres | 630
    03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1020
    03 Alicante/Alacant | 03066 Elda      | Hombres | 610
    03 Alicante/Alacant | 03063 Dénia     | Hombres | 1100
    03 Alicante/Alacant | 03066 Elda      | Mujeres | 630
    03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1020
    03 Alicante/Alacant | 03066 Elda      | Hombres | 610
    03 Alicante/Alacant | 03063 Dénia     | Hombres | 1100
    03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1011
    03 Alicante/Alacant | 03065 Elx/Elche | Hombres | 2359
    03 Alicante/Alacant | 03063 Dénia     | Hombres | 1098
    03 Alicante/Alacant | 03065 Elx/Elche | Mujeres | 2346
    03 Alicante/Alacant | 03063 Dénia     | Mujeres | 1011
    03 Alicante/Alacant | 03065 Elx/Elche | Hombres | 2359
    03 Alicante/Alacant | 03063 Dénia     | Hombres | 1098
    03 Alicante/Alacant | 03065 Elx/Elche | Mujeres | 2346
-------------------------------------------------------------------------------
```

3. Salida tipo `table` con save_mode `append` en la tabla `demo` de DynamoDB

A continuación analizamos qué filas se van a ir insertando en la tabla `demo` a lo largo de la ejecución de las dos rondas.

tras procesar la primera ronda del archivo de entrada de 2024 vemos que la tabla `demo` contiene dos registros:

```
================================================================================
INFORME OVERWRITE, APPEND Y MERGE CON CSV REDUCIDOS
================================================================================


        A continuación vamos a leer los archivos csv de entrada de 2024 y 2025 
        salidas overwrite, append y merge que hemos obtenido.


Ronda 1

--------------------------------------------------------------------------------

[+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_s

...
...
...
3. Salida tipo 'table' en DynamoDB (modo append):

   La tabla 'demo' tiene 4 elementos insertados (modo append):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
```

A continuación se procesa el archivo de 2025 en la siguiente ronda, este es el contenido de la tabla `demo` tras guardar en modo append los registros resultantes de la transformación:

```
3. Salida tipo 'table' en DynamoDB (modo append):

   La tabla 'demo' tiene 6 elementos insertados (modo append):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066 El
```

Explicación detallada de lo que ha ocurrido en la primera ronda

Tras el procesado de 2024 csv se han insertado estos elementos en modo append en la tabla `demo` :

- 03063 Dénia#Hombres (1098)
- 03063 Dénia#Mujeres (1011)
- 03065 Elx/Elche#Hombres (2359)
- 03065 Elx/Elche#Mujeres (2346)

A continuación seguimos con la segunda ronda, donde volvemos a procesar los mismos csv de entrada. Este es el resultado de reprocesar el csv de 2024; se observa un pequeño ruido en la fila de total_ambos_sexos, pero imagino que podemos ignorarlo:

```
Ronda 2

--------------------------------------------------------------------------------

[+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_sg
...
3. Salida tipo 'table' en DynamoDB (modo append):

   La tabla 'demo' tiene 3 elementos insertados (modo append):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066 El
```

A continuación se procesa 2025 en segunda ronda, siendo este el resultado:

```
Ronda 2

--------------------------------------------------------------------------------
...

[+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_sg

3. Salida tipo 'table' en DynamoDB (modo append):

   La tabla 'demo' tiene 3 elementos insertados (modo append):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066 El
```

4. **Salida tipo 'table' en DynamoDB (Modo Merge)**

A continuación analizamos qué filas se van a ir insertando en la tabla `raw_demo` a lo largo de la ejecución de las dos rondas.

tras procesar la primera ronda del archivo de entrada de 2024 vemos que la tabla `raw_demo` contiene dos registros:

```
    ...
================================================================================
INFORME OVERWRITE, APPEND Y MERGE CON CSV REDUCIDOS
================================================================================


        A continuación vamos a leer los archivos csv de entrada de 2024 y 2025 
        salidas overwrite, append y merge que hemos obtenido.


Ronda 1

--------------------------------------------------------------------------------

[+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_sg
...
...

4. Salida tipo 'table' en DynamoDB (modo merge):

   La tabla 'raw_demo' tiene 2 elementos insertados (modo merge):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
```

Continuando en la primera ronda, cuando se procesa el csv de 2025 vemos que la tabla tiene tres archivos insertados:

```
...
[+] Leyendo archivo de entrada C:\Users\user\Documents\PycharmProjects\prueba_sg
...
...
...

4. Salida tipo 'table' en DynamoDB (modo merge):

   La tabla 'raw_demo' tiene 3 elementos insertados (modo merge):
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063 Dé
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065 El
     - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066 El
```

Observaciones

Quería aclarar que la diferencia clave entre append y merge en DynamoDB está en la Clave de Partición (PK) que hemos utilizado.

Aunque ambas tablas tengan 6 elementos al final del test, su el modo como se han insertado los valores no es el mismo.

- **Modo `append` (Tabla `demo`):**

Esta es su clave de partición: municipio_sexo_date (ejemplo: 03063 Dénia#Hombres#2026-08-24).

Eligiéndola de ese modo conseguimos que para distintas distintas ejecuciones siempre se añadan nuevas filas:

► el procesamiento de 2024 insertó 4 registros en modo `append` en la tabla `demo`:


```
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063
Dénia'}, 'sexo': {'S': 'Hombres'}, 'total_ambos_sexos': {'N': '1098'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo_date': {'S': '03063
Dénia#Hombres#2026-08-24'}}
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063
Dénia'}, 'sexo': {'S': 'Mujeres'}, 'total_ambos_sexos': {'N': '1011'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo_date': {'S': '03063
Dénia#Mujeres#2026-08-24'}}
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065
Elx/Elche'}, 'sexo': {'S': 'Hombres'}, 'total_ambos_sexos': {'N': '2359'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo_date': {'S': '03065
Elx/Elche#Hombres#2026-08-24'}}
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065
Elx/Elche'}, 'sexo': {'S': 'Mujeres'}, 'total_ambos_sexos': {'N': '2346'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo_date': {'S': '03065
Elx/Elche#Mujeres#2026-08-24'}}
 -
```


► el procesamiento de 2025 insertó dos registros más para Elda, y sobreescribió los valores de Dénia y Elche porque ejecuté las dos inserciones en el mismo día:


```
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063
Dénia'}, 'sexo': {'S': 'Hombres'}, 'total_ambos_sexos': {'N': '1100'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo_date': {'S': '03063
Dénia#Hombres#2026-08-24'}}
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063
Dénia'}, 'sexo': {'S': 'Mujeres'}, 'total_ambos_sexos': {'N': '1020'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo_date': {'S': '03063
Dénia#Mujeres#2026-08-24'}}
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065
Elx/Elche'}, 'sexo': {'S': 'Hombres'}, 'total_ambos_sexos': {'N': '2359'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo_date': {'S': '03065
Elx/Elche#Hombres#2026-08-24'}}
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065
Elx/Elche'}, 'sexo': {'S': 'Mujeres'}, 'total_ambos_sexos': {'N': '2346'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo_date': {'S': '03065
Elx/Elche#Mujeres#2026-08-24'}}
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066
Elda'}, 'sexo': {'S': 'Hombres'}, 'total_ambos_sexos': {'N': '610'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo_date': {'S': '03066
```

```
Elda#Hombres#2026-08-24'}}
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066
Elda'}, 'sexo': {'S': 'Mujeres'}, 'total_ambos_sexos': {'N': '630'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo_date': {'S': '03066
Elda#Mujeres#2026-08-24'}}
```

► Hay que indicar que si hubiese hecho el procesamiento del 2025 en un dia distinto al día que procesé el archivo de 2024, el modo append habría dejado la tabla `demo` con 8 registros en lugar de 6.

- **Modo `merge` (Tabla `raw_demo`):**

Esta es su clave de partición: municipio_sexo (ejemplo: 03063 Dénia#Hombres#2026-08-24). No incluye la fecha como hicimos en el modo `append` .

Eligiéndola de ese modo conseguimos conseguimos que se modifique el registro en caso de existir, o que se añada si no existe:

► el procesamiento de 2024 insertó 4 registros en modo `merge` en la tabla `raw_demo` :

```
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063
Dénia'}, 'sexo': {'S': 'Hombres'}, 'total_ambos_sexos': {'N': '1098'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo': {'S': '03063
Dénia#Hombres'}}
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063
Dénia'}, 'sexo': {'S': 'Mujeres'}, 'total_ambos_sexos': {'N': '1011'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo': {'S': '03063
Dénia#Mujeres'}}
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065
Elx/Elche'}, 'sexo': {'S': 'Hombres'}, 'total_ambos_sexos': {'N': '2359'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo': {'S': '03065
Elx/Elche#Hombres'}}
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065
Elx/Elche'}, 'sexo': {'S': 'Mujeres'}, 'total_ambos_sexos': {'N': '2346'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo': {'S': '03065
Elx/Elche#Mujeres'}}
```

► el procesamiento de 2025 insertó dos registros más para Elda, y sobreescribió los valores de Dénia y Elche porque ejecuté las dos inserciones en el mismo día:

```
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063
Dénia'}, 'sexo': {'S': 'Hombres'}, 'total_ambos_sexos': {'N': '1100'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo': {'S': '03063
Dénia#Hombres'}}
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03063
Dénia'}, 'sexo': {'S': 'Mujeres'}, 'total_ambos_sexos': {'N': '1020'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo': {'S': '03063
Dénia#Mujeres'}}
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065
```

```
Elx/Elche'}, 'sexo': {'S': 'Hombres'}, 'total_ambos_sexos': {'N': '2359'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo': {'S': '03065
Elx/Elche#Hombres'}}
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03065
Elx/Elche'}, 'sexo': {'S': 'Mujeres'}, 'total_ambos_sexos': {'N': '2346'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo': {'S': '03065
Elx/Elche#Mujeres'}}
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066
Elda'}, 'sexo': {'S': 'Hombres'}, 'total_ambos_sexos': {'N': '610'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo': {'S': '03066
Elda#Hombres'}}
 - {'provincia': {'S': '03 Alicante/Alacant'}, 'municipio': {'S': '03066
Elda'}, 'sexo': {'S': 'Mujeres'}, 'total_ambos_sexos': {'N': '630'},
'load_date': {'S': '2026-08-24'}, 'municipio_sexo': {'S': '03066
Elda#Mujeres'}}
```

Conclusión final. Aunque las salidas sean las mismas, sólo se debe a que la ejecución está hecha el mismo día:

► Si el `merge` se ejecutase en días distintos seguiríamos teniendo 6 filas en `raw_demo`

► Si el `append` se ejecutase en días distintos tendríamos 8 filas en `demo` en lugar de las 6 obtenidas.

Obtener un informe del porcentaje de cobertura de código en las pruebas

pytest-cov permite generar un informe html con el porcentaje de código que cubre nuestra batería de test; este valor será de utilidad si lo incluimos como valor de corte en las Github actions de despliegue:

```
(prueba_sgd_group) PS C:\Users\user\Documents\PycharmProjects\prueba_sgd_group>
============================================================================
platform win32 -- Python 3.11.15, pytest-9.1.1, pluggy-1.6.0
rootdir: C:\Users\user\Documents\PycharmProjects\prueba_sgd_group
configfile: pyproject.toml
plugins: anyio-4.14.2, cov-7.1.0, mock-3.15.1
collected 4 items

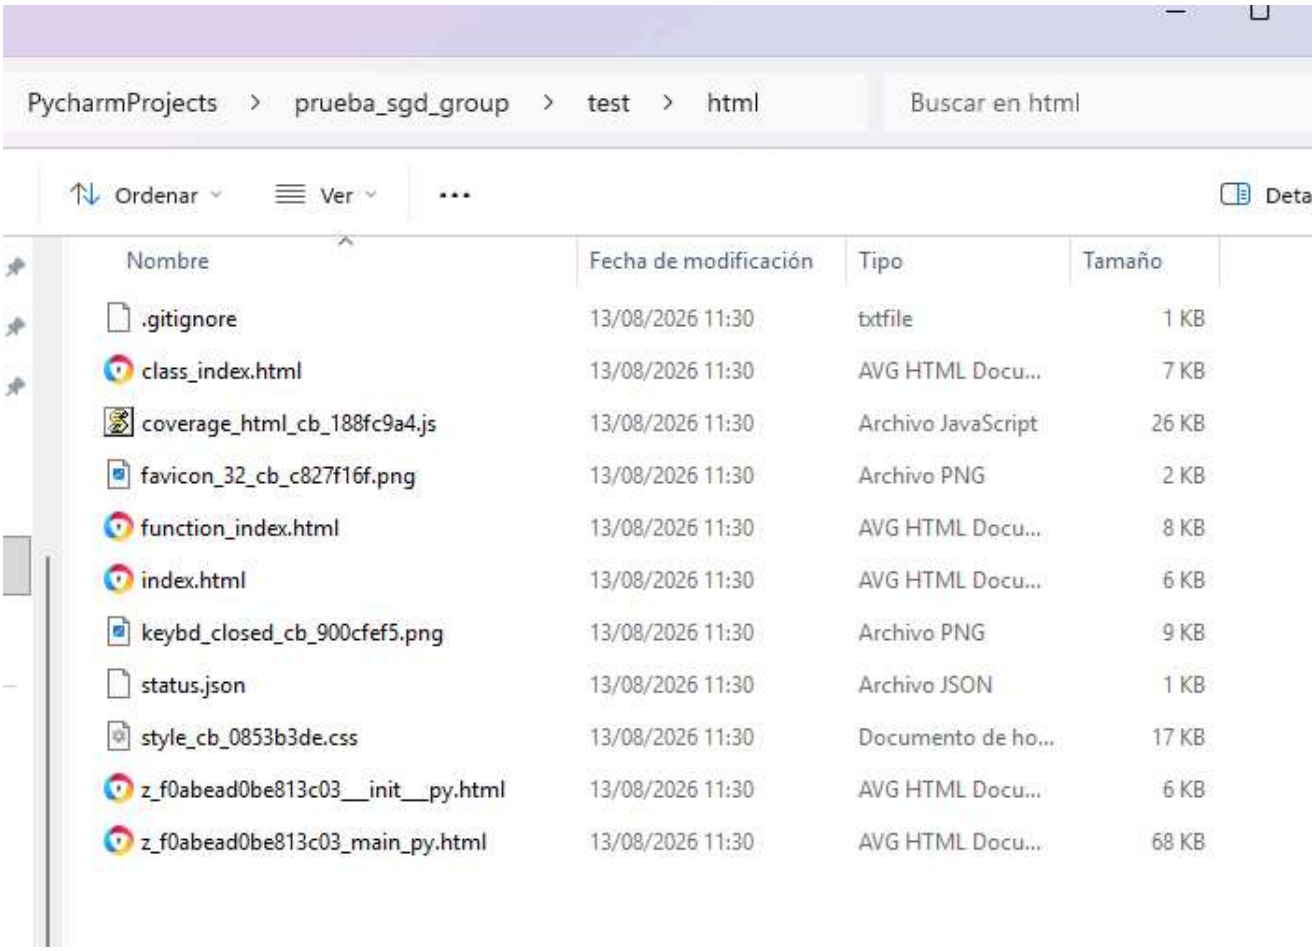
test\test_main.py ....

============================================================================
----------------------------------------------------------------------------

Coverage HTML written to dir test/html
============================================================================
(prueba_sgd_group) PS C:\Users\user\Documents\PycharmProjects\prueba_sgd_group>
ha sido terminado.
CORRECTO: el proceso con PID 22680 (proceso secundario de PID 6216)
```

```
ha sido terminado.
CORRECTO: el proceso con PID 6216 (proceso secundario de PID 20584)
ha sido terminado.
```

Al finalizar la ejecución se ha creado la carpeta que contiene el informe:



Coverage report: 93%

Files | Functions | Classes

coverage.py v7.15.4, created at 2026-08-13 11:30 +0200

File ▲	statements	missing	excluded	coverage
src\prueba_sgd_group__init__.py	2	1	0	50%
src\prueba_sgd_group\main.py	121	8	0	93%
Total	**123**	**9**	**0**	**93%**

coverage.py v7.15.4, created at 2026-08-13 11:30 +0200

src\prueba_sgd_group\main.py: 93% 113 8 0

```python

    @staticmethod
    def interpretador_de_dataflow(dataflow, year):
        spark = SparkSession.getActiveSession()
        dfs = {}

        logger.info("""

        PROCESANDO LAS SECCIÓN DE 'inputs' ...
        =====================================
        """)
        for input_config in dataflow.get("inputs", []):
            name = input_config["name"]
            fmt = input_config["config"]["format"]
            path = input_config["config"]["path"]
            options = input_config.get("options", {})

            archivo_de_entrada = path.replace("{{ year }}", str(year))

            clean_path = archivo_de_entrada.lstrip("/")
            full_path = f"s3a://{bucket_name}/{clean_path}"

            reader = spark.read.format(fmt)
            for key, value in options.items():
                reader = reader.option(key, value)

            try:
                dfs[name] = reader.load(full_path)
            except Exception as e:
                logger.error(f"Fallo al cargar en Spark desde {full_path}: {e}")
                if hasattr(e, 'java_exception'):
                    logger.error(f"Excepción de Java: {e.java_exception}")
                raise e


        logger.info("""

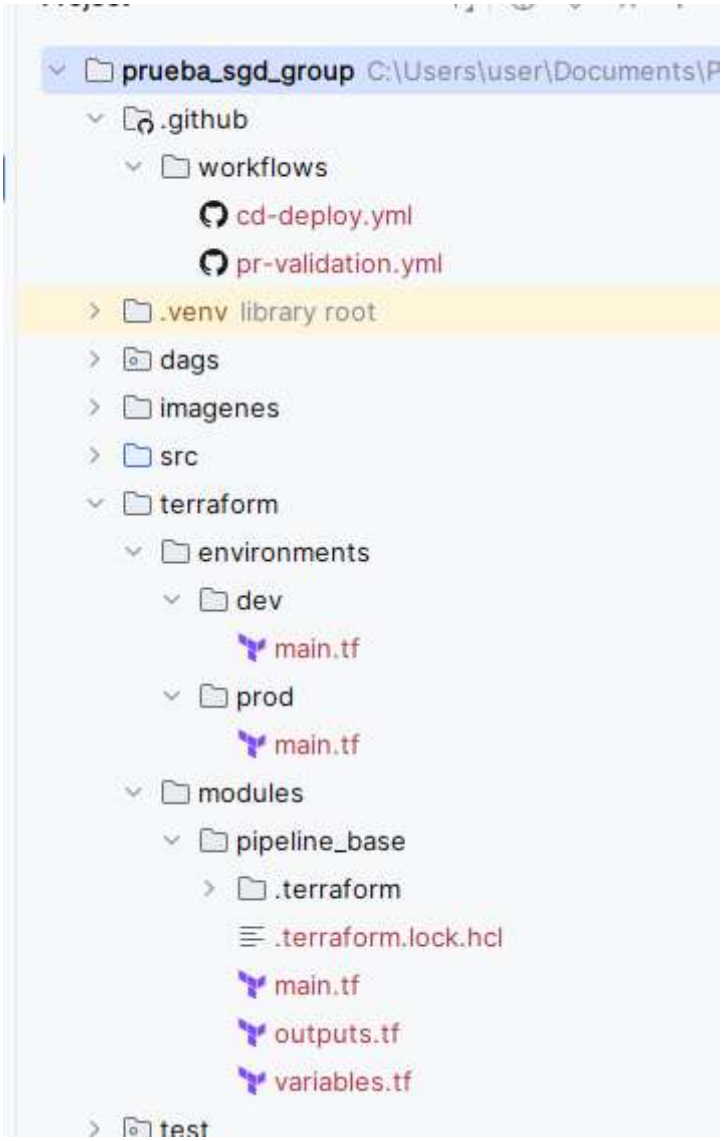
        [+] Atendiendo al enunciado de la prueba, únicamente vamos a procesar los datos provinientes d

        """)
        df_transformado = dfs["demo_data"]


```

Infraestructura as code y workflows CI / CD

Añadimos infrastructura como código con Terraform y github workflows CI/CD:



Validamos los archivos de terraform sin conectar con el entorno de AWS:

- dev:

```
user@DESKTOP-SCNMK3I MINGW64 ~/Documents/PycharmProjects/prueba_sgd_group/terra
Thu Aug 27 08:07:49
$ cd environments/dev/

user@DESKTOP-SCNMK3I MINGW64 ~/Documents/PycharmProjects/prueba_sgd_group/terra
Thu Aug 27 08:07:53
$ terraform init -backend=false
Initializing modules...
- pipeline in ..\..\modules\pipeline_base

Initializing provider plugins...
- Finding hashicorp/aws versions matching "~> 6.0"...
- Installing hashicorp/aws v6.62.0...
- Installed hashicorp/aws v6.62.0 (signed by HashiCorp)

Terraform has created a lock file .terraform.lock.hcl to record the provider
selections it made above. Include this file in your version control repository
so that Terraform can guarantee to make the same selections by default when
```

```
you run "terraform init" in the future.

Terraform has been successfully initialized!

You may now begin working with Terraform. Try running "terraform plan" to see
any changes that are required for your infrastructure. All Terraform commands
should now work.

If you ever set or change modules or backend configuration for Terraform,
rerun this command to reinitialize your working directory. If you forget, other
commands will detect it and remind you to do so if necessary.

user@DESKTOP-SCNMK3I MINGW64 ~/Documents/PycharmProjects/prueba_sgd_group/terra
Thu Aug 27 08:08:14
$ terraform validate
|
| Warning: Deprecated value used
|
|   with module.pipeline.aws_iam_role_policy.mwaa_execution_policy,
|   on ..\..\modules\pipeline_base\iam.tf line 30, in resource "aws_iam_role_po
|   30:   policy = jsonencode({
|   31:     Version = "2012-10-17"
|   32:     Statement = [
|   33:       {
|   34:         Effect   = "Allow"
|   35:         Action   = "airflow:PublishMetrics"
|   36:         Resource = "arn:aws:airflow:${data.aws_region.current.name}:${da
|   37:       },
|   38:       {
|   39:         Effect = "Allow"
|   40:         Action = [
|   41:           "s3:GetObject*",
|   42:           "s3:GetBucket*",
|   43:           "s3:List*",
|   44:           "s3:PutObject*"
|   45:         ]
|   46:         Resource = [
|   47:           aws_s3_bucket.pipeline_bucket.arn,
|   48:           "${aws_s3_bucket.pipeline_bucket.arn}/*"
|   49:         ]
|   50:       },
|   51:       {
|   52:         Effect = "Allow"
|   53:         Action = [
|   54:           "logs:CreateLogStream",
|   55:           "logs:CreateLogGroup",
|   56:           "logs:PutLogEvents",
|   57:           "logs:GetLogEvents",
|   58:           "logs:GetLogRecord",
|   59:           "logs:GetLogGroupFields",
|   60:           "logs:GetQueryResults",
|   61:           "logs:DescribeLogGroups"
|   62:         ]
```

```
  63:         Resource = "arn:aws:logs:${data.aws_region.current.name}:${data
  64:       },
  65:       {
  66:         Effect   = "Allow"
  67:         Action   = "cloudwatch:PutMetricData"
  68:         Resource = "*"
  69:       },
  70:       {
  71:         Effect = "Allow"
  72:         Action = [
  73:           "sqs:ChangeMessageVisibility",
  74:           "sqs:DeleteMessage",
  75:           "sqs:GetQueueAttributes",
  76:           "sqs:GetQueueUrl",
  77:           "sqs:ReceiveMessage",
  78:           "sqs:SendMessage"
  79:         ]
  80:         Resource = "arn:aws:sqs:${data.aws_region.current.name}:*:airfl
  81:       },
  82:       {
  83:         Effect = "Allow"
  84:         Action = [
  85:           "elasticmapreduce:RunJobFlow",
  86:           "elasticmapreduce:AddJobFlowSteps",
  87:           "elasticmapreduce:DescribeCluster",
  88:           "elasticmapreduce:DescribeStep",
  89:           "elasticmapreduce:ListSteps",
  90:           "elasticmapreduce:TerminateJobFlows",
  91:           "elasticmapreduce:ListInstances"
  92:         ]
  93:         Resource = "*"
  94:       },
  95:       {
  96:         Effect   = "Allow"
  97:         Action   = "secretsmanager:GetSecretValue"
  98:         Resource = aws_secretsmanager_secret.emr_credentials.arn
  99:       },
 100:       {
 101:         Effect = "Allow"
 102:         Action = "iam:PassRole"
 103:         Resource = [
 104:           aws_iam_role.emr_service_role.arn,
 105:           aws_iam_role.emr_instance_profile_role.arn
 106:         ]
 107:       }
 108:     ]
 109:   })

  The deprecation originates from module.pipeline.data.aws_region.current.nam

name is deprecated. Use region instead.
```

```
Success! The configuration is valid, but there were some validation warnings as
```

- prod:

```
user@DESKTOP-SCNMK3I MINGW64 ~/Documents/PycharmProjects/prueba_sgd_group/terra
Thu Aug 27 08:08:40
$ cd ../prod/

user@DESKTOP-SCNMK3I MINGW64 ~/Documents/PycharmProjects/prueba_sgd_group/terra
Thu Aug 27 08:10:15
$ terraform init -backend=false
Initializing modules...
- pipeline in ..\..\modules\pipeline_base

Initializing provider plugins...
- Finding hashicorp/aws versions matching "~> 6.0"...
- Installing hashicorp/aws v6.62.0...
- Installed hashicorp/aws v6.62.0 (signed by HashiCorp)

Terraform has created a lock file .terraform.lock.hcl to record the provider
selections it made above. Include this file in your version control repository
so that Terraform can guarantee to make the same selections by default when
you run "terraform init" in the future.

Terraform has been successfully initialized!

You may now begin working with Terraform. Try running "terraform plan" to see
any changes that are required for your infrastructure. All Terraform commands
should now work.

If you ever set or change modules or backend configuration for Terraform,
rerun this command to reinitialize your working directory. If you forget, other
commands will detect it and remind you to do so if necessary.

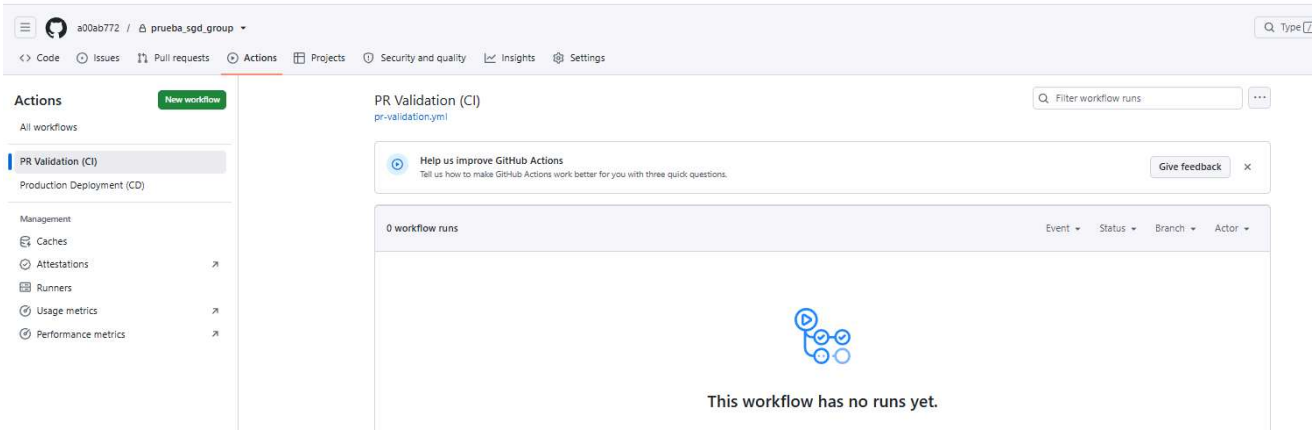
user@DESKTOP-SCNMK3I MINGW64 ~/Documents/PycharmProjects/prueba_sgd_group/terra
Thu Aug 27 08:10:32
$ terraform validate

╷
│ Warning: Deprecated value used
│
│   with module.pipeline.aws_iam_role_policy.mwaa_execution_policy,
│   on ..\..\modules\pipeline_base\iam.tf line 30, in resource "aws_iam_role_po
│   30:   policy = jsonencode({
│   31:     Version = "2012-10-17"
│   32:     Statement = [
│   33:       {
│   34:         Effect   = "Allow"
│   35:         Action   = "airflow:PublishMetrics"
│   36:         Resource = "arn:aws:airflow:${data.aws_region.current.name}:${d
```

```
37:       },
38:       {
39:         Effect = "Allow"
40:         Action = [
41:           "s3:GetObject*",
42:           "s3:GetBucket*",
43:           "s3:List*",
44:           "s3:PutObject*"
45:         ]
46:         Resource = [
47:           aws_s3_bucket.pipeline_bucket.arn,
48:           "${aws_s3_bucket.pipeline_bucket.arn}/*"
49:         ]
50:       },
51:       {
52:         Effect = "Allow"
53:         Action = [
54:           "logs:CreateLogStream",
55:           "logs:CreateLogGroup",
56:           "logs:PutLogEvents",
57:           "logs:GetLogEvents",
58:           "logs:GetLogRecord",
59:           "logs:GetLogGroupFields",
60:           "logs:GetQueryResults",
61:           "logs:DescribeLogGroups"
62:         ]
63:         Resource = "arn:aws:logs:${data.aws_region.current.name}:${data
64:       },
65:       {
66:         Effect   = "Allow"
67:         Action   = "cloudwatch:PutMetricData"
68:         Resource = "*"
69:       },
70:       {
71:         Effect = "Allow"
72:         Action = [
73:           "sqs:ChangeMessageVisibility",
74:           "sqs:DeleteMessage",
75:           "sqs:GetQueueAttributes",
76:           "sqs:GetQueueUrl",
77:           "sqs:ReceiveMessage",
78:           "sqs:SendMessage"
79:         ]
80:         Resource = "arn:aws:sqs:${data.aws_region.current.name}:*:airfl
81:       },
82:       {
83:         Effect = "Allow"
84:         Action = [
85:           "elasticmapreduce:RunJobFlow",
86:           "elasticmapreduce:AddJobFlowSteps",
87:           "elasticmapreduce:DescribeCluster",
88:           "elasticmapreduce:DescribeStep",
89:           "elasticmapreduce:ListSteps",
```

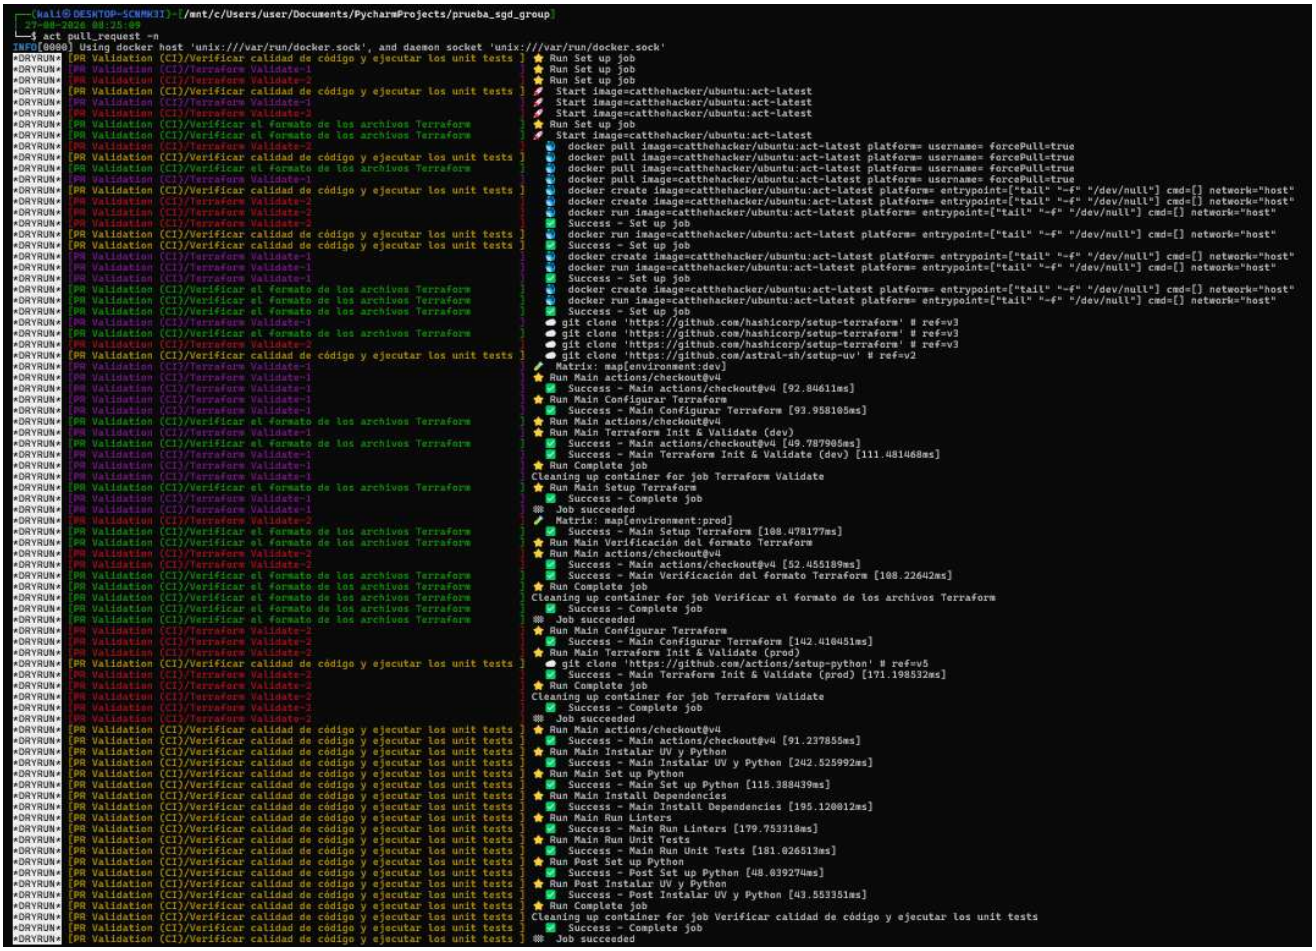
```
    90:           "elasticmapreduce:TerminateJobFlows",
    91:           "elasticmapreduce:ListInstances"
    92:         ]
    93:         Resource = "*"
    94:       },
    95:       {
    96:         Effect   = "Allow"
    97:         Action   = "secretsmanager:GetSecretValue"
    98:         Resource = aws_secretsmanager_secret.emr_credentials.arn
    99:       },
   100:       {
   101:         Effect = "Allow"
   102:         Action = "iam:PassRole"
   103:         Resource = [
   104:           aws_iam_role.emr_service_role.arn,
   105:           aws_iam_role.emr_instance_profile_role.arn
   106:         ]
   107:       }
   108:     ]
   109:   })
  
   The deprecation originates from module.pipeline.data.aws_region.current.name
  
 name is deprecated. Use region instead.
 
Success! The configuration is valid, but there were some validation warnings as
```

Añadimos los workflow de Github:



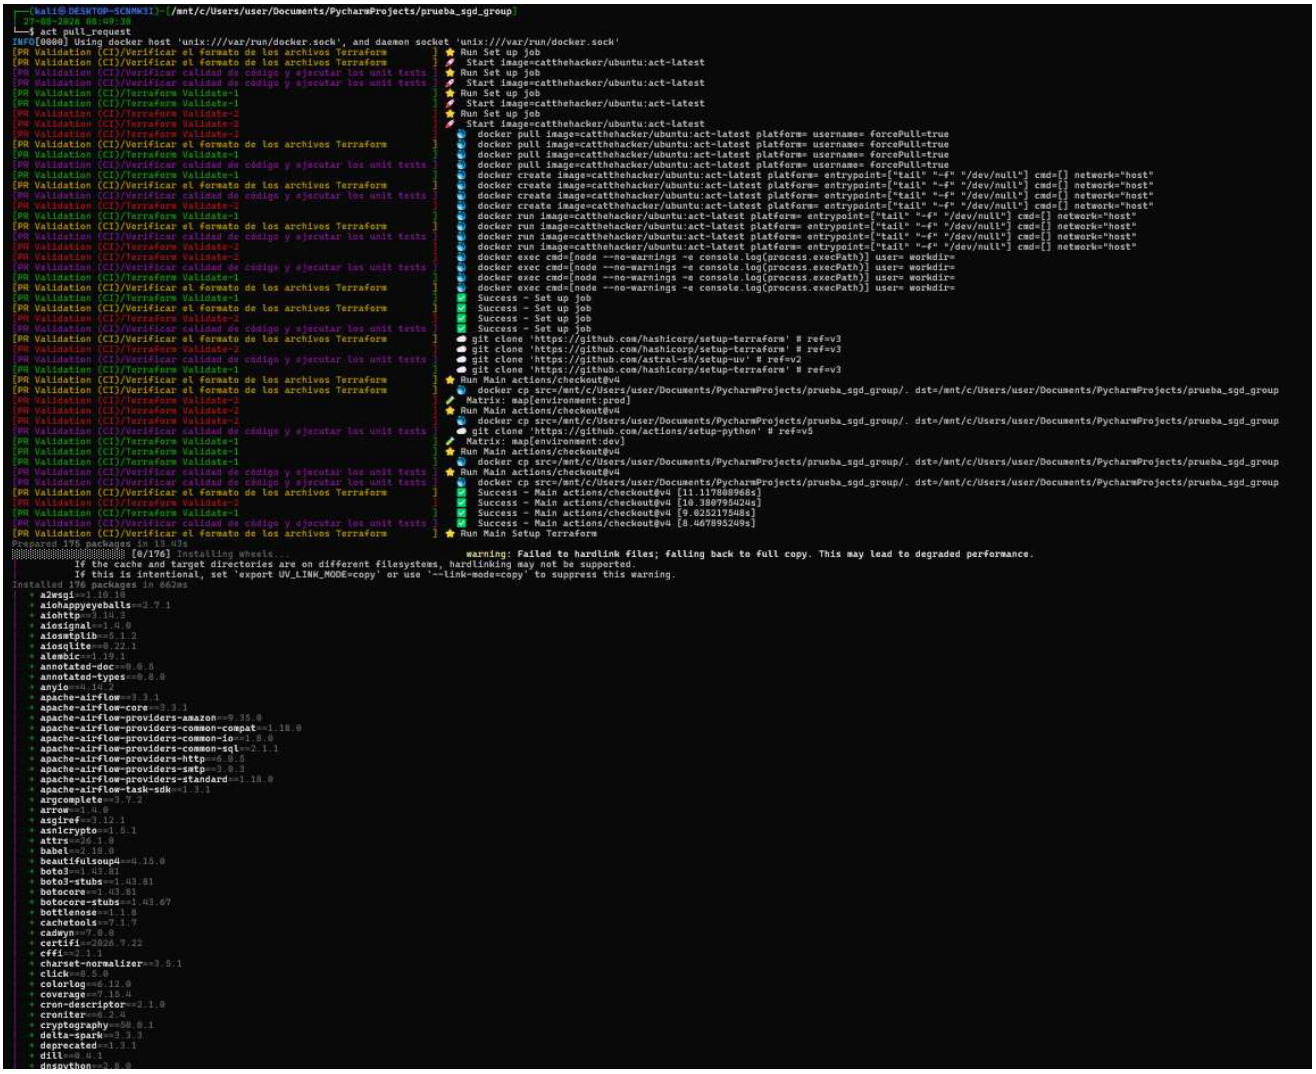
Para asegurarnos de que los workflow funcionan vamos a usar `act` (nektos/act). Este comando ejecutará los workflows en contenedores Docker locales, simulando lo que haría el runner de GitHub. Se puede ejecutar en modo dry run, sin instalar los componentes:

```
$ act pull_request -n
```



o bien lo podemos ejecutar en modo real, instalando los componentes en docker:

```
$ act pull_request
```


┌──(kali㉿DESKTOP-SCNMK3I)-[/mnt/c/Users/user/Documents/PycharmProjects/prueba_sgd_group]
└─$ act pull_request
INFO[0000] Using docker host 'unix:///var/run/docker.sock', and daemon socket 'unix:///var/run/docker.sock'
[PR Validation (CI)/Verificar el formato de los archivos Terraform] ⭐ Run Set up job
[PR Validation (CI)/Verificar el formato de los archivos Terraform] 🚀 Start image=catthehacker/ubuntu:act-latest
[PR Validation (CI)/Verificar calidad de código y ejecutar los unit tests] ⭐ Run Set up job
[PR Validation (CI)/Verificar calidad de código y ejecutar los unit tests] 🚀 Start image=catthehacker/ubuntu:act-latest
[PR Validation (CI)/Terraform Validate-1] ⭐ Run Set up job
[PR Validation (CI)/Terraform Validate-1] 🚀 Start image=catthehacker/ubuntu:act-latest
[PR Validation (CI)/Terraform Validate-2] ⭐ Run Set up job
[PR Validation (CI)/Terraform Validate-2] 🚀 Start image=catthehacker/ubuntu:act-latest
[PR Validation (CI)/Terraform Validate-2] 🐳 docker pull image=catthehacker/ubuntu:act-latest platform= username= forcePull=true
[PR Validation (CI)/Verificar el formato de los archivos Terraform] 🐳 docker pull image=catthehacker/ubuntu:act-latest platform= username= forcePull=true
[PR Validation (CI)/Terraform Validate-1] 🐳 docker pull image=catthehacker/ubuntu:act-latest platform= username= forcePull=true
[PR Validation (CI)/Verificar calidad de código y ejecutar los unit tests] 🐳 docker pull image=catthehacker/ubuntu:act-latest platform= username= forcePull=true
[PR Validation (CI)/Terraform Validate-1] 🐳 docker create image=catthehacker/ubuntu:act-latest platform= entrypoint=["tail" "-f" "/dev/null"] cmd=[] network="host"
[PR Validation (CI)/Verificar el formato de los archivos Terraform] 🐳 docker create image=catthehacker/ubuntu:act-latest platform= entrypoint=["tail" "-f" "/dev/null"] cmd=[] network="host"
[PR Validation (CI)/Verificar calidad de código y ejecutar los unit tests] 🐳 docker create image=catthehacker/ubuntu:act-latest platform= entrypoint=["tail" "-f" "/dev/null"] cmd=[] network="host"
[PR Validation (CI)/Terraform Validate-2] 🐳 docker create image=catthehacker/ubuntu:act-latest platform= entrypoint=["tail" "-f" "/dev/null"] cmd=[] network="host"
[PR Validation (CI)/Terraform Validate-1] 🐳 docker run image=catthehacker/ubuntu:act-latest platform= entrypoint=["tail" "-f" "/dev/null"] cmd=[] network="host"
[PR Validation (CI)/Verificar el formato de los archivos Terraform] 🐳 docker run image=catthehacker/ubuntu:act-latest platform= entrypoint=["tail" "-f" "/dev/null"] cmd=[] network="host"
[PR Validation (CI)/Verificar calidad de código y ejecutar los unit tests] 🐳 docker run image=catthehacker/ubuntu:act-latest platform= entrypoint=["tail" "-f" "/dev/null"] cmd=[] network="host"
[PR Validation (CI)/Terraform Validate-2] 🐳 docker run image=catthehacker/ubuntu:act-latest platform= entrypoint=["tail" "-f" "/dev/null"] cmd=[] network="host"
[PR Validation (CI)/Terraform Validate-2] 🐳 docker exec cmd=[node --no-warnings -e console.log(process.execPath)] user= workdir=
[PR Validation (CI)/Verificar calidad de código y ejecutar los unit tests] 🐳 docker exec cmd=[node --no-warnings -e console.log(process.execPath)] user= workdir=
[PR Validation (CI)/Terraform Validate-1] 🐳 docker exec cmd=[node --no-warnings -e console.log(process.execPath)] user= workdir=
[PR Validation (CI)/Verificar el formato de los archivos Terraform] 🐳 docker exec cmd=[node --no-warnings -e console.log(process.execPath)] user= workdir=
[PR Validation (CI)/Terraform Validate-1] ✅ Success - Set up job
[PR Validation (CI)/Verificar el formato de los archivos Terraform] ✅ Success - Set up job
[PR Validation (CI)/Terraform Validate-1] ✅ Success - Set up job
[PR Validation (CI)/Verificar calidad de código y ejecutar los unit tests] ✅ Success - Set up job
[PR Validation (CI)/Verificar el formato de los archivos Terraform] 🐳 git clone 'https://github.com/hashicorp/setup-terraform' # ref=v3
[PR Validation (CI)/Terraform Validate-2] 🐳 git clone 'https://github.com/hashicorp/setup-terraform' # ref=v3
[PR Validation (CI)/Verificar calidad de código y ejecutar los unit tests] 🐳 git clone 'https://github.com/astral-sh/setup-uv' # ref=v2
[PR Validation (CI)/Terraform Validate-1] 🐳 git clone 'https://github.com/hashicorp/setup-terraform' # ref=v3
[PR Validation (CI)/Verificar el formato de los archivos Terraform] ⭐ Run Main actions/checkout@v4
[PR Validation (CI)/Verificar el formato de los archivos Terraform] 🐳 docker cp src=/mnt/c/Users/user/Documents/PycharmProjects/prueba_sgd_group/. dst=/mnt/c/Users/user/Documents/PycharmProjects/prueba_sgd_group
[PR Validation (CI)/Terraform Validate-2] 🧪 Matrix: map[environment:prod]
[PR Validation (CI)/Terraform Validate-2] ⭐ Run Main actions/checkout@v4
[PR Validation (CI)/Terraform Validate-2] 🐳 docker cp src=/mnt/c/Users/user/Documents/PycharmProjects/prueba_sgd_group/. dst=/mnt/c/Users/user/Documents/PycharmProjects/prueba_sgd_group
[PR Validation (CI)/Verificar calidad de código y ejecutar los unit tests] 🐳 git clone 'https://github.com/actions/setup-python' # ref=v5
[PR Validation (CI)/Terraform Validate-1] 🧪 Matrix: map[environment:dev]
[PR Validation (CI)/Terraform Validate-1] ⭐ Run Main actions/checkout@v4
[PR Validation (CI)/Terraform Validate-1] 🐳 docker cp src=/mnt/c/Users/user/Documents/PycharmProjects/prueba_sgd_group/. dst=/mnt/c/Users/user/Documents/PycharmProjects/prueba_sgd_group
[PR Validation (CI)/Verificar calidad de código y ejecutar los unit tests] ⭐ Run Main actions/checkout@v4
[PR Validation (CI)/Verificar calidad de código y ejecutar los unit tests] 🐳 docker cp src=/mnt/c/Users/user/Documents/PycharmProjects/prueba_sgd_group/. dst=/mnt/c/Users/user/Documents/PycharmProjects/prueba_sgd_group
[PR Validation (CI)/Verificar el formato de los archivos Terraform] ✅ Success - Main actions/checkout@v4 [11.117808968s]
[PR Validation (CI)/Terraform Validate-2] ✅ Success - Main actions/checkout@v4 [10.398795424s]
[PR Validation (CI)/Terraform Validate-1] ✅ Success - Main actions/checkout@v4 [9.025217548s]
[PR Validation (CI)/Verificar calidad de código y ejecutar los unit tests] ✅ Success - Main actions/checkout@v4 [8.467895249s]
[PR Validation (CI)/Verificar el formato de los archivos Terraform] ⭐ Run Main Setup Terraform
Prepared 175 packages in 13.43s
⠙⠙⠙⠙⠙⠙⠙⠙⠙⠙⠙⠙⠙⠙⠙⠙ [0/176] Installing wheels...
warning: Failed to hardlink files; falling back to full copy. This may lead to degraded performance.
If the cache and target directories are on different filesystems, hardlinking may not be supported.
If this is intentional, set `export UV_LINK_MODE=copy` or use `--link-mode=copy` to suppress this warning.
Installed 176 packages in 662ms
+ a2wsgi==1.10.10
+ aiohappyeyeballs==2.7.1
+ aiohttp==3.14.3
+ aiosignal==1.4.0
+ aiosmtplib==5.1.2
+ aiosqlite==0.22.1
+ alembic==1.18.1
+ annotated-doc==0.0.5
+ annotated-types==0.8.0
+ anyio==4.12.1
+ apache-airflow==3.3.1
+ apache-airflow-core==3.3.1
+ apache-airflow-providers-amazon==9.35.0
+ apache-airflow-providers-common-compat==1.16.0
+ apache-airflow-providers-common-io==1.8.0
+ apache-airflow-providers-common-sql==2.1.1
+ apache-airflow-providers-http==6.0.5
+ apache-airflow-providers-smtp==2.0.3
+ apache-airflow-providers-standard==1.10.0
+ apache-airflow-task-sdk==1.3.1
+ argcomplete==3.7.2
+ arrow==1.4.0
+ asgiref==3.12.1
+ asnlcrypto==1.5.1
+ attrs==26.1.0
+ babel==2.18.0
+ beautifulsoup4==4.15.0
+ boto3==1.43.81
+ boto3-stubs==1.43.81
+ botocore==1.43.81
+ botocore-stubs==1.43.67
+ bottleneck==1.1.0
+ cachetools==7.1.7
+ cadwyn==7.0.0
+ certifi==2026.7.22
+ cffi==2.1.1
+ charset-normalizer==3.5.1
+ click==8.5.0
+ colorlog==6.12.0
+ coverage==7.15.4
+ cron-descriptor==2.1.0
+ croniter==6.2.4
+ cryptography==50.0.1
+ delta-spark==3.3.3
+ deprecated==1.3.1
+ dill==0.4.1
+ dnspython==2.8.0