Prueba Técnica

Data Engineer – Nivel 2

Data Technologies Unit at SDG Group

2025

El objetivo de la prueba técnica es que puedas demostrar tus capacidades de desarrollo en el marco de Big Data y Spark además de los conceptos básicos del ciclo de vida de data engineering.

Somos conscientes de que algunos de los componentes tecnológicos que proponemos para esta prueba técnica quizá no los conozcas, pero pensamos que por tus capacidades podrás adquirir un conocimiento básico en estos días para sacar adelante la prueba. Los puntos a tratar en la prueba técnica serían los siguientes:

1. Descomprimir el fichero **assets.zip** recibido junto con este documento.

2. Deberás desarrollar un programa basado en Python (preferentemente) o Scala que haga lo siguiente:

Descripción del programa: El programa realizado en Python (preferentemente) o Scala debería, dirigido por el fichero de metadatos "**metadata.json**", ejecutar un proceso que lea datos desde los orígenes descritos, ejecute las transformaciones indicadas y escriba los datos en los destinos especificados. Es muy importante que sea un programa que cambie su comportamiento dinámicamente vía los metadatos propuestos y que no sea un desarrollo ad hoc.

3. Este código tiene que ser compilado y ejecutado usando el csv "**data2024.csv**" como datos de entrada:

4. Después de la primera ejecución, se pide volver a ejecutar usando el csv "**data2025.csv**". Es necesario **demostrar el comportamiento solicitado en las salidas** (overwrite, append y merge).

5. Adicionalmente, se piden 2 códigos (totalmente aparte del punto 1) para realizar las siguientes comprobaciones (por ejemplo, **un test unitario**):

    a. Qué filas han cambiado del fichero de 2024 al fichero de 2025

    b. Qué problemas de calidad del dato tiene el fichero de 2025 (Ambos sexos != Hombres + Mujeres)

Copyright© SDG Group

6. Como ultimo punto, se pide que en un documento de PowerPoint se haga una presentación de cómo se podría implantar un motor como el solicitado (suponiendo funcionalidades extendidas de lectura, transformacion y escritura, no únicamente las solicitadas en esta prueba) en una arquitectura de datos basada en alguna de las clouds más habituales (Azure, Google, AWS, Cloudera). Ese diseño debe incluir un Airflow como orquestador, ademas del resto de servicios necesarios para industrializar una solución de este tipo (bases de datos, storages, etc...). Incluir también los ciclos de CICD correspondientes para realizar el despliegue de todos los componentes de software que fueran necesarios. En este documento no es necesario explicar ni exponer nada sobre la creación y despliegue de los servicios en cloud mediante IaC (infraestructure as code).

Si tienes que priorizar en qué te enfocas de la prueba técnica porque no tienes suficiente tiempo, el principal objetivo es que nos desmuestres tus capacidades de Python/Scala y Spark. Así que nos gustaría indicarte que el framework de procesamiento dirigido por metadatos que diseñes e implementes es en lo que más vamos a valorar en términos técnicos y en términos de presentación.

IMPORTANTE

En caso de usar **ChatGPT**, **Deepseek** o cualquier otro servicio de IA para la obtención de código, configuraciones, etc... para esta prueba técnica nos gustaría ver algún **listado de prompts usados** y cómo has ido "conversando" con dichos servicios.

Si en algún momento tienes algo que comentar con nosotros, o necesitas que movamos la fecha o la hora de presentación por algún tema personal, no dudes en contactarnos a:

- Xabier Gil (xabier.gil@sdggroup.com)
- Angel Alvarez (angel.alvarez@sdggroup.com)
- Jose Carlos Perez (josecarlos.perez@sdggroup.com)

Sin más, muchas gracias por la entrevista y esperamos vernos contigo de nuevo en breve.

Por otro lado, por favor, confírmanos que has recibido la prueba técnica y si la aceptas.

Copyright© SDG Group